5115056030 HW2 Appliances Energy Prediction

家用電器能源消耗預測：多元線性回歸、特徵選擇與自回歸延伸

5115056030｜HW2 正式報告｜CRISP-DM 六階段｜2026 年 10 月

資料集： Appliances Energy Prediction（Kaggle／UCI）　**研究問題：**以同期環境及照明資訊估計 10 分鐘家電耗電（Wh），並比較加入實際歷史耗電的 ARX 線性回歸。

> **研究倫理與評估聲明**：Train/Validation/Test 按時間切分；所有 scaler、feature selector 與線性模型只在 Training 擬合；根據 Validation RMSE 選擇最佳純環境模型。Test 不用於挑選模型。OLS 傳統 PI 需獨立、常態、等變異等假設，不能當成已校準的警報界限。本文的原論文數值與本研究使用不同資料切分，**僅供背景比較**，不可解讀為同場排名。最終 GPT 對話完整匯出 PDF 需由學生在 ChatGPT 介面另行完成。

摘要

研究使用 19,735 筆、每 10 分鐘一次的低能耗住宅量測資料，原始 29 欄中排除日期及目標後有 27 個數值特徵。資料無缺失，但 `rv1`、`rv2` 完全重複且屬人工隨機控制變數，故主要實驗保留 25 個感測與氣象候選特徵。以時間順序劃分 Training 13,814、Validation 2,960 及 Test 2,961 筆。在 Training 範圍內比較 SelectKBest、RFE、SFS、Lasso 和 Permutation Importance，分別選 14／20／25 特徵，搭配 LinearRegression、Ridge、Lasso 共 45 種組合。Validation 最佳是 Permutation Importance 14 特徵的 LinearRegression（RMSE 84.71 Wh），在 Test 上 RMSE 89.20 Wh、R^2 0.0366。預先定義的延伸實驗加入前 10／20／30 分鐘的實際耗電值（總共 28 特徵），在同一 Test 上 RMSE 61.40 Wh、R^2 0.5435，殘差 Durbin–Watson 從 0.583 提高到 2.070；但仍存在異質變異、厚尾

與高 VIF。傳統 95% OLS PI 整體涵蓋率約 95.47%，高耗電 >400 Wh 僅約 24.64%，不宜直接做安全告警門檻。部署模組已實際儲存／讀取 Pipeline，並針對基載與高峰負荷示範 95% PI 與係數貢獻。

1. Business Understanding（商業理解）

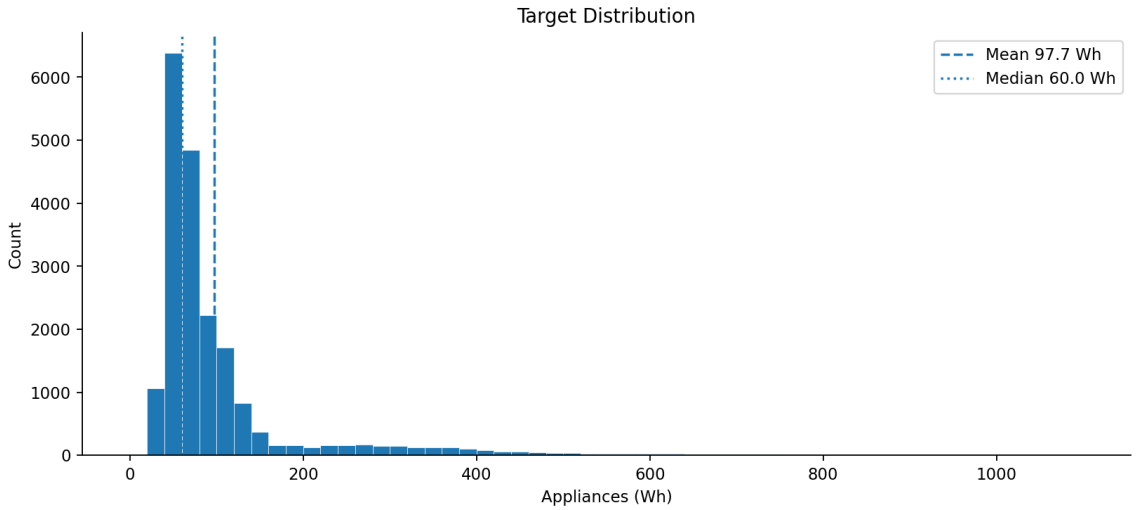
住宅 HEMS（Home Energy Management System）需要估計家庭設備於每個 10 分鐘觀測視窗的耗電，協助儀表板顯示、感測器一致性檢查與負荷變化觀察。研究優先採 **`sklearn.LinearRegression`**：目的不只是提高 R^2，也要維持透明可解釋的輸入、係數與統計診斷。方案 A 使用同期溫濕度、氣象及照明量測估計 `Appliances`，**不是預先預報未來**；方案 B 進一步利用已實測的前一至前三個時間點電器耗電（ARX）提供連續更新的即時估計。兩個方案在生產端所需資訊不同，實際效果不可不加條件地相互替代。

成功準則：提供可重現的數據切分、5 種特徵選擇與回歸模型評估；比較 MAE、MSE、RMSE、R^2、Adjusted R^2；完成五大回歸假設、95% CI／PI、涵蓋率及實際推論示範。與企業需求連結但不宣稱已於實際住宅上線。

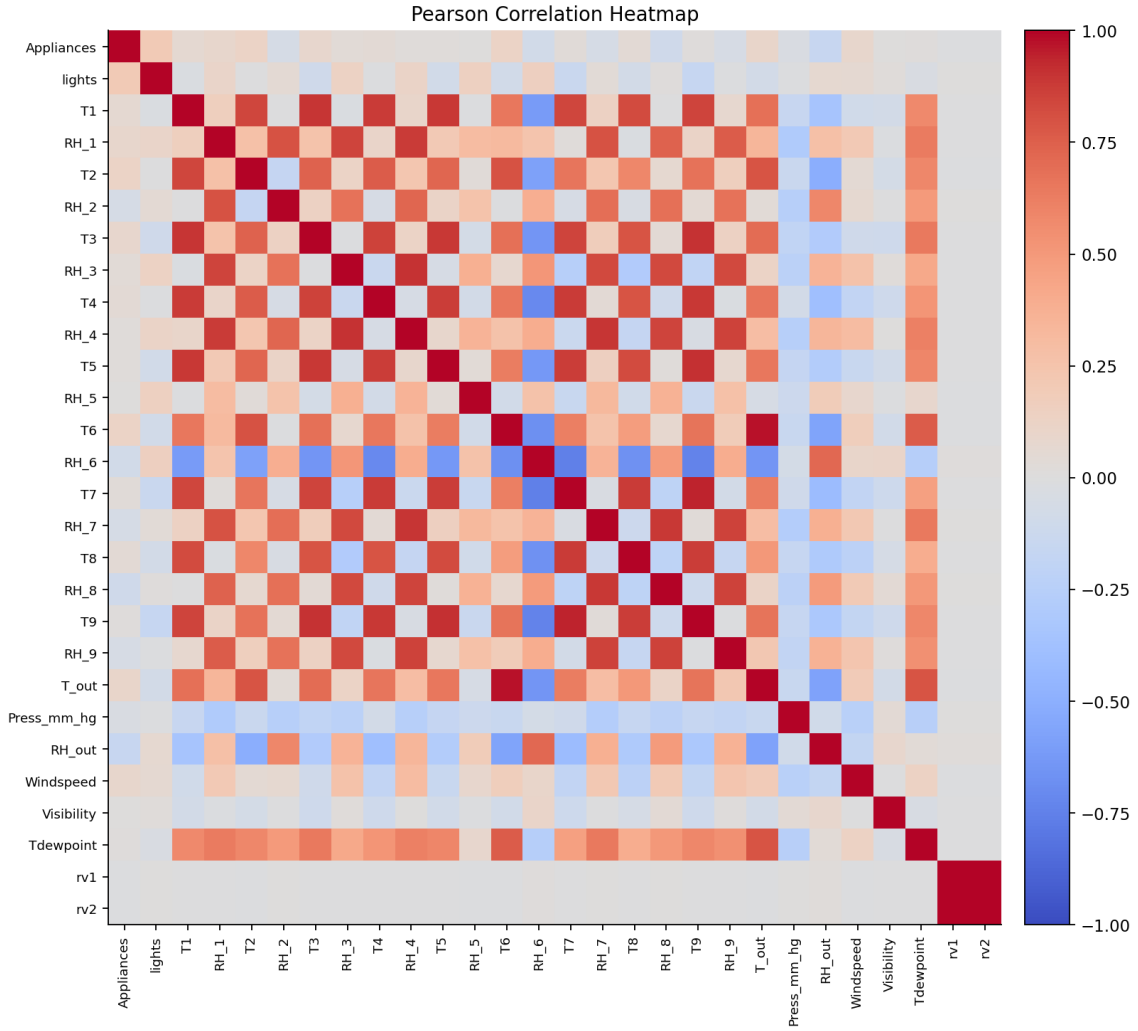
2. Data Understanding（資料理解）

資料來源：Kaggle、UCI。取樣時段為 2016/01/11 17:00 至 2016/05/27 18:00，連續每 10 分鐘一筆，共 **19,735 × 29**，缺失儲存格 0、完全重複資料列 0、重複時間點 0。原始數值候選特徵 27 個（照明 1、`T1–T9` 及 `RH_1–RH_9` 共 18、天氣 6、隨機欄位 2）；目標 `Appliances` 不納入特徵數。

`Appliances` 平均 **97.69 Wh**、中位數 **60 Wh**、Q1 **50 Wh**、Q3 **100 Wh**、最大 **1,080 Wh**。IQR 上界 175 Wh，超過的高負荷記錄 **2,138 筆（10.83%）**，不逕自刪除。`rv1` 與 `rv2` 每筆完全一樣；溫度 `T6` 與 `T_out` 的 Pearson r 約 0.9748。單一變數與目標最大的 r 是 `lights` 約 +0.1973，無法僅靠單變量關係判斷多元模型能力。目標相隔 10 分鐘的自相關 r 約 0.753，故不能任意打散 Train/Test。



Step 2：Target 右偏分布

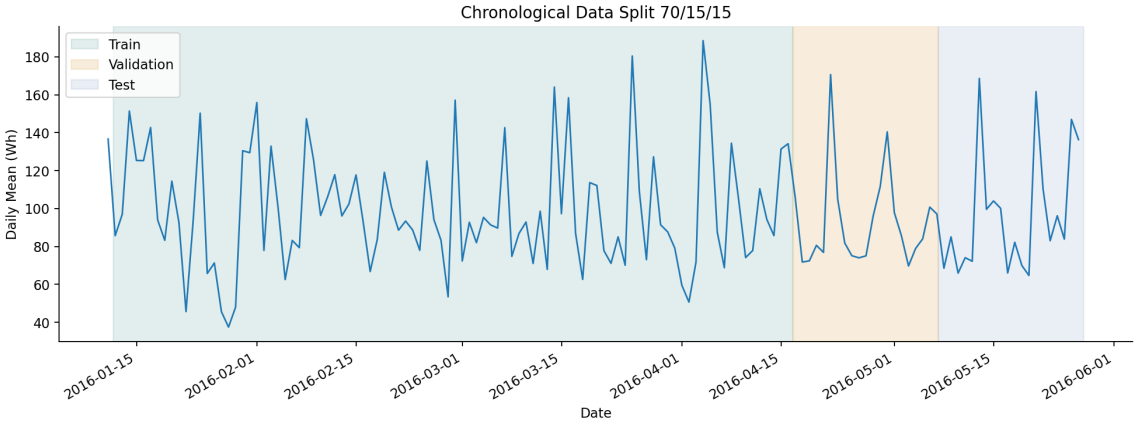


Step 2：相關矩陣（25+特徵）

3. Data Preparation（資料準備）

原始欄位 29 個，排除 `date`（只用來排序）、`Appliances`（目標）及 `rv1`、`rv2`（已知無意義的重複隨機對照欄位），保留 **25 個數值候選特徵**。不填補缺失值、不刪除尖峰。主 `LinearRegression` 不需要為尺度而標準化，但為公平比較 Ridge／Lasso 與一致推論，**僅以 Training 呼叫 `StandardScaler.fit`**，Validation/Test 僅用 `transform`。SFS 的交叉驗證各折於折內 fit scaler；Permutation Importance 在 Training 內另做時間 holdout。

時間分割	筆數	時間範圍	用途
Training (70%)	13,814	2016/01/11–04/16	特徵選擇、標準化、擬合
Validation (15%)	2,960	2016/04/16–05/07	選超參與最佳模型
Test (15%)	2,961	2016/05/07–05/27	最終一次評估、模型診斷



Step 3：依日期切分

由於 Validation/Test 時段晚於 Train，此方式主要衡量時間外推能力；照明為 0 的比例亦由 Train 73.28% 升至 Test 88.25%，顯示分布漂移。**觀測到 Test 的分布不代表允許用它調整模型。**

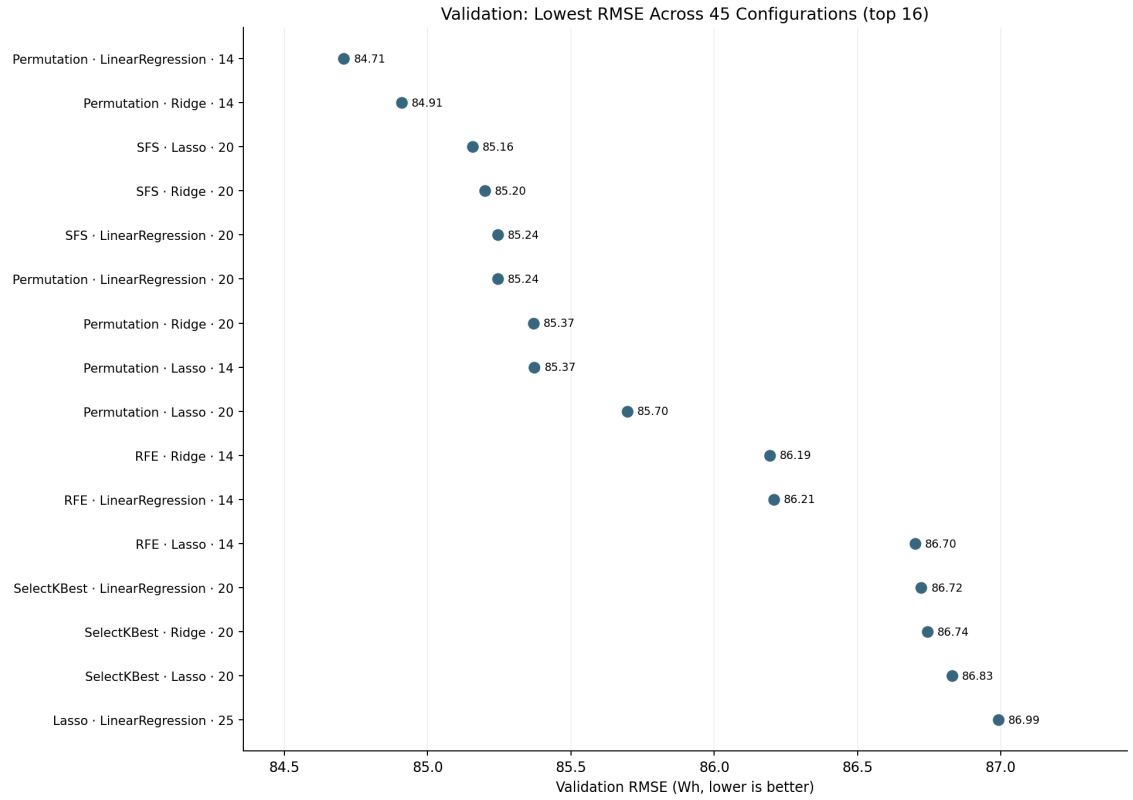
4. Feature Selection & Modeling（特徵選擇與建模）

在 25 個候選特徵中，訓練期間執行 SelectKBest（f-regression）、RFE、SFS（訓練區間 3 折 TimeSeriesSplit）、Lasso 係數排序及 Permutation Importance（Train 內部 80/20 時序 holdout），選擇 14、20、25 個特徵；每一組分別訓練 LinearRegression、Ridge（alpha=10）、Lasso（alpha=0.1）。總數 5 × 3 × 3＝**45 組**。k=25 為完整候選基線，雖仍列示方法，實際沒有刪除特徵。最佳組合僅按 Validation RMSE 排序；其他隨機步驟固定種子 42。

Validation 排名	方法	k	模型	RMSE (Wh)	R^2
1	Permutation	14	LinearRegression	84.71	0.1566
2	Permutation	14	Ridge	84.91	0.1526
3	SFS	20	Lasso	85.16	0.1477

Validation 排名	方法	k	模型	RMSE (Wh)	R^2
4	SFS	20	Ridge	85.20	0.1468
5	SFS	20	LinearRegression	85.24	0.1459
6	Permutation	20	LinearRegression	85.24	0.1459
7	Permutation	20	Ridge	85.37	0.1434
8	Permutation	14	Lasso	85.37	0.1434
9	Permutation	20	Lasso	85.70	0.1368
10	RFE	14	Ridge	86.19	0.1268

被選中的 14 個特徵： `lights`, `RH_1`, `T2`, `RH_2`, `T3`, `RH_3`, `T6`, `RH_6`, `T7`, `T8`, `RH_8`, `T_out`, `RH_out`, `Tdewpoint`。其最大 VIF **382.45**，顯示特徵選擇改善 Validation RMSE 並不代表共線性已消除。個別係數不可隨便解讀為因果效果。



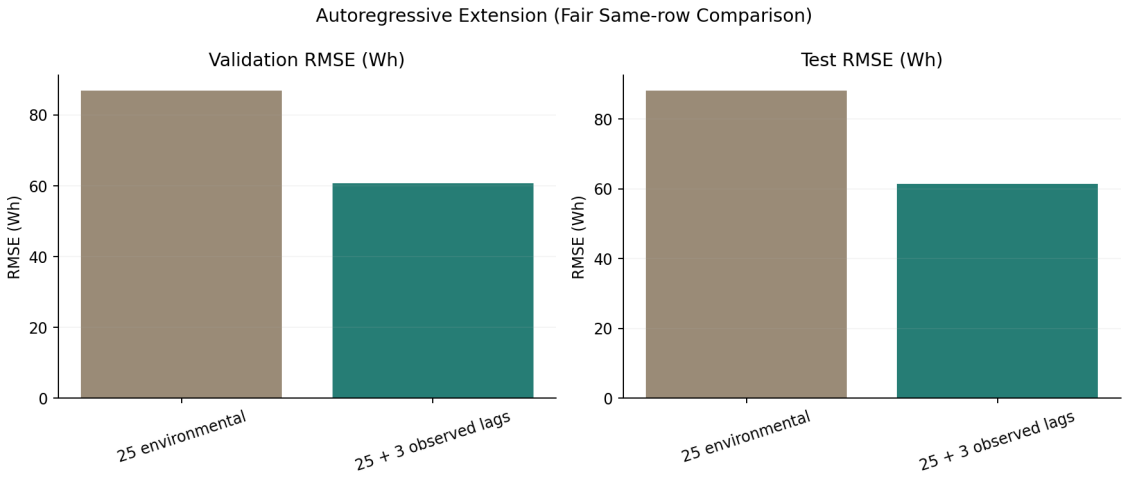
Step 4：Validation RMSE 排序

4.1 比較模型：加入歷史耗電的 Auto Regression

在**資料切分之前**先為每個時間點建立 `Appliances_lag1`, `Appliances_lag2`, `Appliances_lag3`，然後依原本日期切分，這三欄分別使用 t−1、t−2、t−3 的**實際觀測值**，不可直接使用當期 Target。移除資料開頭 3 筆無 lag 的觀測後，B 的 Train 是 13,811 筆，但 Validation/Test 均保持原 2,960／2,961 筆。使用同樣對齊後的 Train 建立 25 環境特徵控制模型與 28 特徵 ARX 模型，以完全相同 Test 列公平比較。

對照組	分割	特徵數	MAE	RMSE	R^2
Env-25	Validation	25	54.52	86.96	0.1111

對照組	分割	特徵數	MAE	RMSE	R^2
Env-25	Test	25	57.51	88.25	0.0570
Env+3lag-28	Validation	28	28.86	60.68	0.5672
Env+3lag-28	Test	28	28.85	61.40	0.5435



Step 4：Lag 模型 RMSE 改善

5. Evaluation（深入評估）

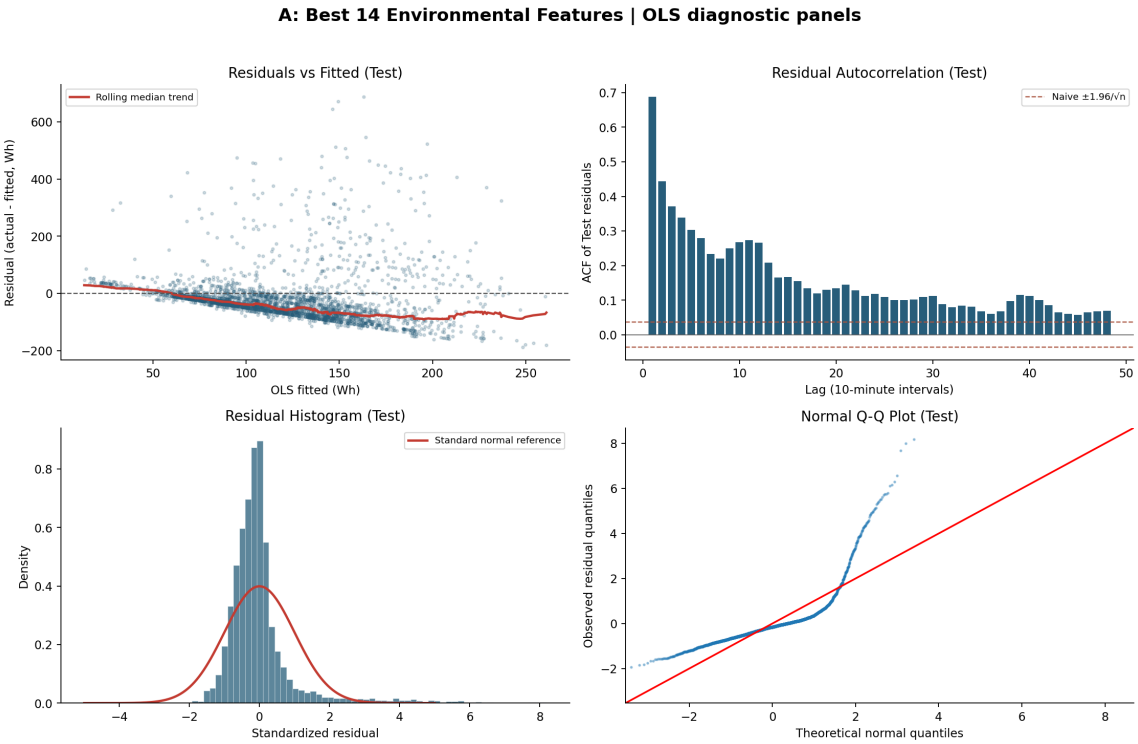
Best Model A 14 特徵的 Test 結果： MAE 60.17、MSE 7,955.90、RMSE **89.20 Wh**、R^2 **0.0366**、Adjusted R^2 **0.0320**。**方案 B 28 特徵 Test 結果：** MAE 28.85、MSE 3,769.77、RMSE **61.40 Wh**、R^2 **0.5435**、Adjusted R^2 **0.5391**。OLS 作為與鎖定的 scikit-learn 模型數值等價的 Train-only 擬合，用 `statsmodels.get_prediction(...).summary_frame(alpha=0.05)` 取得平均 95% CI 與個別 95% PI；**沒有**用 Test 重新估計回歸係數。

Test 殘差指標	A-14	Env-25	B-28
DW	0.5831	0.5955	2.0704
ACF lag1	+0.6876	+0.6892	-0.0359
BP LM	254.53	285.67	286.23
BP p	3.32e-46	4.44e-46	1.31e-44
Skewness	3.157	2.960	3.211
Excess kurtosis	14.122	13.063	21.691

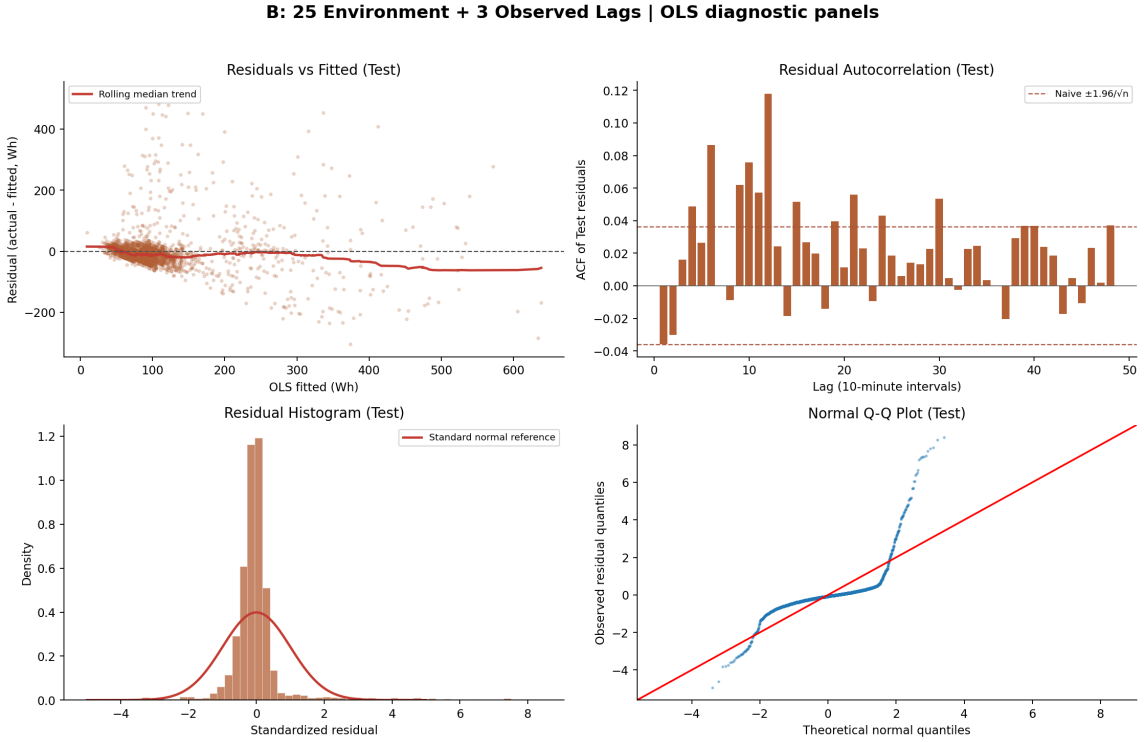
5.1 五大假設

1. **線性形式：** Residuals vs Fitted Values 出現不同預測負荷下的殘差形態與尖峰，線性條件平均假設可能不足；圖形只提供診斷，不可直接視為已形式檢定通過。
2. **獨立性：** A-14 Test DW **0.5831**，殘差具強烈正自相關；加入 lag 的 B-28 Test DW **2.0704**，一階 ACF 約 −0.0359，改善明顯，其他延遲仍需另看 ACF。

3. **等變異：** Breusch–Pagan Test p 值極小（例如 B 約 1.31e−44），**拒絕同質變異的虛無假設**。
4. **常態性：** Q–Q Plot 與 Histogram 厚尾；Jarque–Bera／Omnibus 檢定拒絕常態，對常態建構的 PI 必須保守解釋。
5. **多重共線性：** Training VIF 最大 A-14 **382.45**、B-28 **405.34**；篩選後仍有高度相依特徵，個別係數具不穩定風險。



Step 5：方案 A 四聯殘差診斷

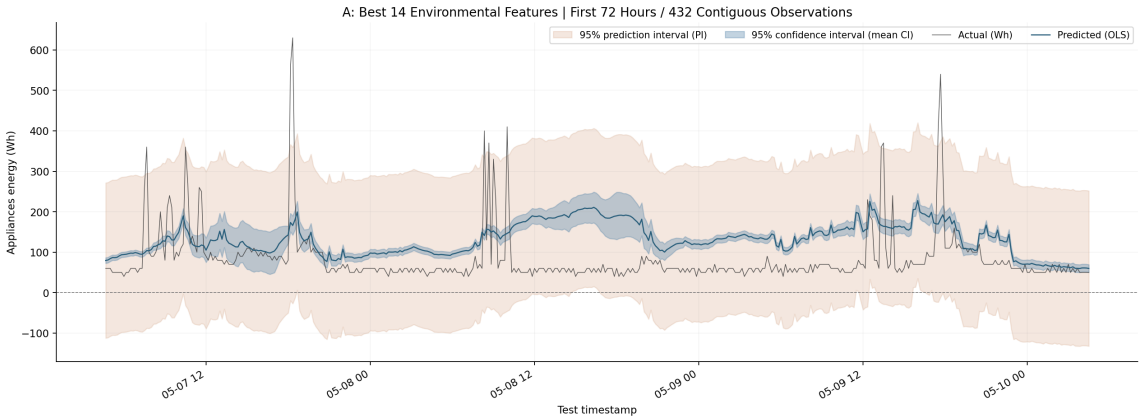


Step 5：方案 B 四聯殘差診斷

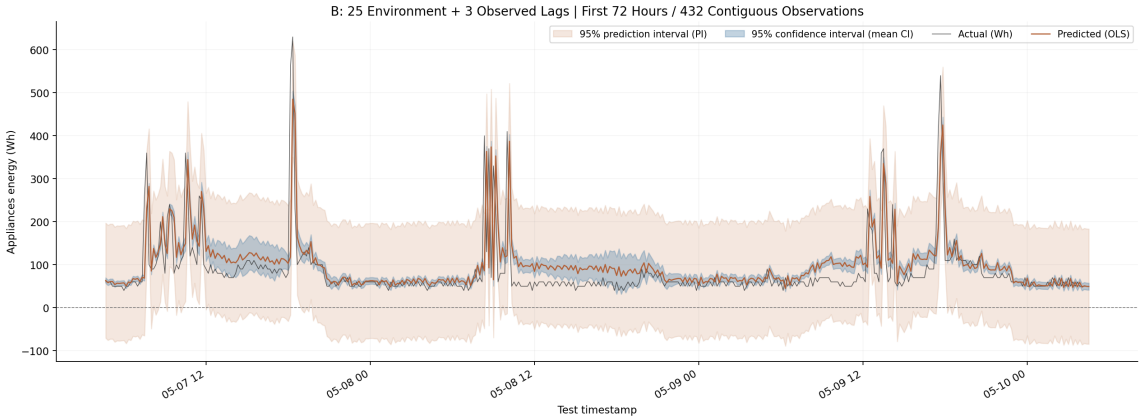
5.2 預測區間與涵蓋率

95% CI（**條件平均值**）比 95% PI（**單筆實際耗電**）狹窄。PI 由 OLS 傳統 iid-normal 公式取得，沒有對變異不齊與時間相關做區間校準。圖中同時呈現 Actual、Predicted、95% CI、95% PI，並特別放大 Test 首 432 筆（72 小時）。

涵蓋率統計	A-14	B-28
Test PI Coverage	96.49%	95.47%
平均 PI 寬度 (Wh)	384.21	268.07
PI 下界小於 0	95.47%	87.20%
>400 Wh 涵蓋率	0.00%	24.64%

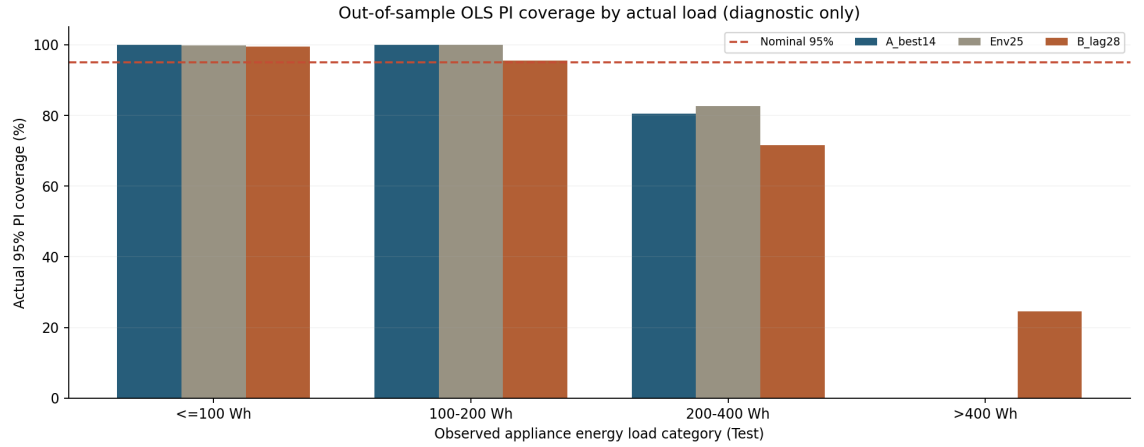


方案 A：連續 72 小時 Test 預測／區間



方案 B：連續 72 小時 Test 預測／區間

關鍵限制：當低負荷占多數時，整體 Coverage 接近 95% 不表示高負荷可靠。傳統線性 PI 大量出現負下界（耗電量物理上不可為負），且對 >400 Wh 尖峰的覆蓋率很低。假如將此 PI 直接當自動警報閾值，容易高估其可信度。改善方向為異方差／分位數迴歸、時間依賴校準與分組 Coverage 驗證，尚未在此作業實作，不得宣稱已完成。



分負荷 PI 真實涵蓋率

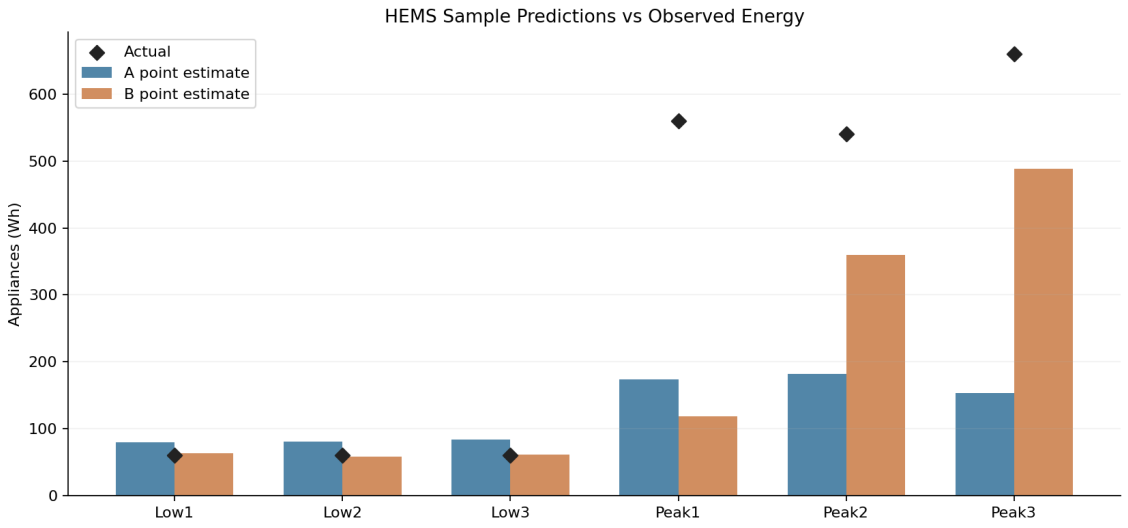
6. Deployment（模型部署與新樣本推論）

已將鎖定 Step 4 的 scaler、14 個特徵選擇器及 LinearRegression 包成可由 `joblib.load` 載入的 `sklearn.Pipeline`（方案 A）；方案 B 為 scaler + 28 特徵 LinearRegression Pipeline。**沒有使用 Test 重新擬合 scaler／特徵／模型**；只使用原 Training 的觀測重新建立數值等價的 `statsmodels.OLS`，用於傳統 CI/PI 推論。載入存檔 Pipeline 後逐筆檢查，與原鎖定模型預測值一致。需注意：`joblib.load` 使用 pickle 機制，只能載入可信來源檔案。

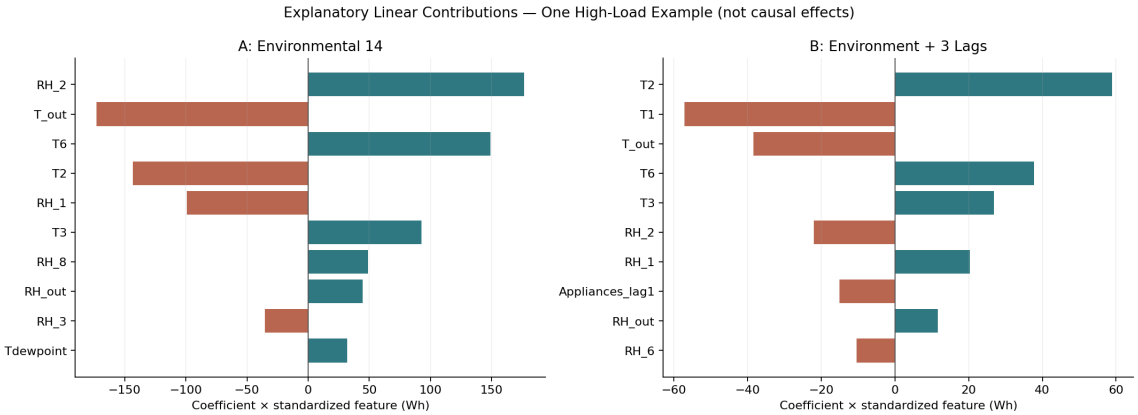
6.1 低負荷與尖峰樣本實測

從 Test 中以實際負荷與照明選取 3 筆低負荷、3 筆已發生尖峰作**事後展示**，不作模型選擇或調參。若實際系統部署，不能依未觀測的真實 `Appliances` 先選樣本。

日期／情境	Actual	模型	點預測 (Wh)	95% PI 下界	95% PI 上界
2016-05-07 04:40／低負荷	60	A-14	79.56	-112.25	271.37
2016-05-07 04:40／低負荷	60	B-28	63.40	-70.37	197.16
2016-05-07 04:50／低負荷	60	A-14	80.66	-111.15	272.46
2016-05-07 04:50／低負荷	60	B-28	58.15	-75.61	191.91
2016-05-07 05:00／低負荷	60	A-14	84.07	-107.73	275.87
2016-05-07 05:00／低負荷	60	B-28	60.94	-72.82	194.70
2016-05-07 18:10／已觀測尖峰	560	A-14	173.41	-19.62	366.44
2016-05-07 18:10／已觀測尖峰	560	B-28	118.05	-16.63	252.73
2016-05-09 17:40／已觀測尖峰	540	A-14	181.83	-11.22	374.88
2016-05-09 17:40／已觀測尖峰	540	B-28	359.18	224.34	494.03
2016-05-13 08:00／已觀測尖峰	660	A-14	153.15	-38.81	345.10
2016-05-13 08:00／已觀測尖峰	660	B-28	488.30	354.18	622.42



Step 6：六筆樣本點預測



Step 6：尖峰案例之係數貢獻分解

係數貢獻解釋：對經訓練期平均／標準差標準化的特徵，單筆預測可寫成 `intercept + Σ(coef_i × z_i)`，其中 `z_i=(x_i − TrainMean_i)/TrainSD_i`。每個貢獻項及原值皆已輸出 `demo_feature_contributions.csv`。由於特徵共線性高，係數貢獻只描述此模型運算結果，不代表改變單一室溫會因果改變該幅度的耗電量。

6.2 HEMS 系統情境、操作限制與風險

- **方案 A**：感測器溫濕度／氣象與同期照明量測已經取得時，估計同一時段的電器負荷，可用於基載趨勢探索、缺值合理性初判或感測器訊號異常的輔助指標，但其低 Test R^2 與高峰失準使其**不適合單獨**做關鍵安全判斷。
- **方案 B**：若有真實時間序列電表，系統可保留最近 3 個 10 分鐘時段的 `Appliances` 實測值，結合同期其他感測器提供**連續更新的負荷估計／輔助預警**。**需先取得滯後用電量**，沒有真實滯後數據不得把當期預測值冒充歷史測量值；如果連續遞迴預測須另做多步驗證。
- **輸入管控**：按 `deployment_schema.json` 的 feature order、單位及數值型態送入，禁止將 Target 或 `date` 當環境特徵；日期用來排序與 lag 對齊。必須監測時間間隔、遺漏值、感測器故障及跨季節分布漂移。
- **PI 警告**：大量負下界與負荷尖峰 coverage 不足，不能將傳統 OLS PI 直接當作具有 95% 校準保證的警報區間；展示時可以保留負值說明模型限制，但實務呈現應另行設計物理限制與校準方法。

6.3 實際部署輸出

`5115056030_step6_outputs/HEMS_environment_14_pipeline.joblib` 和 `HEMS_lag_28_pipeline.joblib` 可供再次載入推論；`deployment_schema.json` 定義欄位順序；`demo_predictions_95PI.csv` 收錄個別 CI／PI；`demo_feature_contributions.csv` 收錄所有標準化係數貢獻與截距；PNG 是本研究實測結果。專案主程式 `5115056030_hw2.py` 亦能從原始 CSV 重新執行六階段。

7. 學術來源、NotebookLM 研究與方法對照

【NotebookLM 摘要】網路同主題解法與原始文獻研究

本研究透過 Google NotebookLM 彙整 UCI 原始文獻（Candanedo et al., 2017）與 Kaggle 社群高分公開解法。

1. **問題背景與特徵特性**：本研究資料集涵蓋低能耗住宅 4.5 個月之室內溫濕度（$T1_{T9}$、RH_1、RH_9）、室外氣象與兩個無關隨機變數（`rv1`, `rv2`）。目標變數 `Appliances` 呈強烈右偏分布（待機基載約

40~60 Wh，尖峰高達 1,080 Wh）；且特徵存在嚴重多重共線性（如 `rv1` 與 `rv2` 完全共線、室內外溫濕度高度相關）。

2. **傳統線性回歸瓶頸**：單純利用環境溫濕度進行 OLS、Ridge 或 Lasso 多元線性回歸時，測試集解釋力（R2R^2）僅約 0.05~0.16。主因是家電開關屬非線性階躍變化，線性模型無法捕捉突發尖峰，且殘差具強烈正自相關與異質變異，嚴重違反了傳統回歸假設。
3. **特徵工程與選擇**：主流解法透過 RFE 或 Lasso 成功剔除無統計顯著性的隨機變數（`rv1`, `rv2`）。加入時間週期特徵（如距離午夜秒數 NSM、小時）能捕捉居民日常作息規律；導入自回歸**滯後項（Lag features）**則顯著利用相鄰時間的強慣性，使線性模型的 R2R^2 躍升至 0.55~0.60 以上。
4. **主流與更優解法比較**：相較於線性模型，非線性集成樹模型（如 Random Forest、GBM 與 XGBoost）能自動學習時間與溫濕度的非線性交互作用，測試集 R2R^2 提升至 0.57 以上（RMSE 降至約 66 Wh），大幅突破傳統回歸之預測瓶頸。

摘要來源說明：以上四項為學生本人提供的 **Google NotebookLM 研究摘要原文**，由 GPT 協助排版。下方原始論文數字另有逐頁核實；摘要中的概括值不全都對應本研究或原論文的同一模型與資料切分，請以各表格標註的來源為準。NotebookLM 原始筆記連結及問答畫面目前未提供，需由學生自行保存佐證。特別是：本研究的 Lag Test R2=0.5435R^2=0.5435（未達「0.55 以上」）；原始論文 RF Test R2=0.54R^2=0.54，不是全部樹模型都超過 0.57；原論文並**未**在其四模型比較中報告 XGBoost。`rv1` 和 `rv2` 是我們於建模前依已知隨機欄位排除，不能宣稱其由本研究 RFE/Lasso 自動剔除。

本研究實測模型 vs. 原始論文與網路主流更優解法綜合比較表

本研究的三組 Test 皆使用 **2016/05/07–05/27 的時序保留資料（2,961 筆）**。Candanedo et al. (2017) 的測試集及模型特徵工程不同，文獻 Table 5 論文**完整模型**包含 NSM／星期／週末等週期特徵；不是本文的 14、25 或 28 個特徵，也不是同樣的切分。以下只作**方法與量級對照**，不跨資料切分宣稱優劣或直接合併排名。

模型名稱與數據來源	特徵配置	Test RMSE (Wh)	Test R^2	優／缺點	統計假設特性
本研究 A：OLS	14 環境／照明特徵	89.20	0.0366	可解釋；高峰低估	VIF 高；自相關、異方差、非正態
本研究 Env：OLS	25 環境／照明特徵	88.25	0.0570	全特徵基線；簡單	同上
本研究 B：ARX-OLS	25 環境＋3 實測滯後	61.40	0.5435	RMSE 下降、一階自相關改善	DW 接近 2；仍異方差、厚尾、高 VIF
原論文 LM	環境＋照明＋NSM／日期	93.18	0.16	傳統線性基線	論文未提供本報告相同五項診斷
原論文 SVM Radial	同論文全特徵	70.74	0.52	RBF 可處理非線性	無 OLS 五假設之直接適用性
原論文 GBM	同論文全特徵	66.65	0.57	樹集成捕捉非線性尖峰	不同於 OLS；可解釋性較低
原論文 RF	同論文全特徵	68.48	0.54	非線性／交互作用建模	不同於 OLS；個別係數不存在

模型名稱與數據來源	特徵配置	Test RMSE (Wh)	Test R^2	優／缺點	統計假設特性
2023 後續研究 XGB	另一文獻處理與切分	63.86	0.61	梯度提升，調參需求高	非原論文模型；不同分割不可直接排名

原論文資料出處：Candanedo, L. M., Feldheim, V., & Deramaix, D. (2017). Data driven prediction models of energy use of appliances in a low-energy house, Energy and Buildings, 140, 81–97. **Table 5（期刊頁碼 91）**，DOI: https://doi.org/10.1016/j.enbuild.2017.01.083 ，公開全文：https://orbi.umons.ac.be/bitstream/20.500.12907/23357/1/1-s2.0-S0378778816308970-main.pdf 。

後續研究：Data-Driven Modeling of Appliance Energy Usage, Energies 2023，Table 2，https://www.mdpi.com/1996-1073/16/22/7536 。此研究的 XGB 63.86 Wh／R^2 0.61 為**該文自身測試結果**，非本研究實跑，也非 2017 原論文數據；此例純屬研究背景。

【GPT 輔助內容】AI 協作歷程說明

1. **Step 1 — Business Understanding：**協助核對 Kaggle 特徵數限制（14–39，不含 Target），辨別同時間點估計與未來預報的不同，以及研究目的與 CRISP-DM 規格。
2. **Step 2 — Data Understanding：**提供欄位字典、EDA 程式、缺失值／重複值／分布／Pearson 相關矩陣與統計結果核對，依實際原始 CSV 製圖。
3. **Step 3 — Data Preparation：**討論依時間 70/15/15 切分、移除重複的 `rv1`／`rv2`、嚴格限制 25 個候選特徵、避免 Train/Validation/Test 洩漏，及 Pipeline scaler 的訓練集擬合原則。
4. **Step 4 — Modeling：**協作撰寫與驗證五種特徵選擇（SelectKBest、RFE、SFS、Lasso、Permutation Importance）、14／20／25 特徵、三種回歸與 VIF 比較；依 Validation 選模型並進行 Lag 延伸實驗。
5. **Step 5 — Evaluation：**協助 statsmodels OLS 五大假設診斷（DW、ACF、BP、Q–Q、JB／Omnibus、VIF）、傳統 95% CI／PI、72 小時放大圖與 PI 負荷分組涵蓋率驗證。
6. **Step 6 — Deployment：**協助將鎖定模型封裝為可載入的 sklearn Pipeline、測試低負荷與尖峰樣本、點預測與區間、係數貢獻拆解及 HEMS 使用限制。
7. **文獻與編排：**GPT 將學生本人提交的 NotebookLM 摘要放入報告，另依原始論文 Table 5 查對 LM/SVM/GBM/RF 真實數值；協助報告、README 與提交結構。**GPT 並未代替學生操作 NotebookLM**。

另需提供完整 GPT 對話紀錄 PDF：本報告的「GPT 輔助內容」說明並不等同課堂要求的全程對話 PDF，請學生使用 ChatGPT 分享／列印或 pdfCrowd 匯出實際對話，並於最後 ZIP 中加入。此處不會編造或偽造未取得的對話紀錄。

8. Conclusion 與作業要求檢查

已完成完整 CRISP-DM：選題與問題定義、原始資料品質檢查、時間切分、5 種 Feature Selection、45 組 LinearRegression／Ridge／Lasso 比較、最終 Test、五大假設、95% CI／PI、Lag 延伸對照，以及部署 Pipeline 的重新載入與實際預測示範。純環境模型的泛化解釋力有限，而加入真實歷史耗電的線性模型大幅改善 RMSE 與一階殘差相關，但並未解決極端負荷的區間可靠性及共線性。未來研究可依季節與負荷區間校準、分析遺漏資料、比較具可解釋性的非線性方法，但不宣稱已部署於真實 HEMS。

提交清單：`5115056030_hw2.py`、`5115056030_hw2_report.md`、`5115056030_hw2_report.pdf`、完整資料集、模型與圖檔、兩個明示的 AI 協作區塊、NotebookLM 研究摘要、其他結果資料。**尚須學生本人另行附上完整 ChatGPT 對話 PDF**，再提交最終 ZIP。

參考文獻與資料來源

1. Candanedo, L. M., Feldheim, V., & Deramaix, D. (2017). Data driven prediction models of energy use of appliances in a low-energy house. Energy and Buildings, 140, 81–97. https://doi.org/10.1016/j.enbuild.2017.01.083 （見全文 Table 5）。
2. UCI Appliances Energy Prediction, https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction
3. Kaggle Appliances Energy Prediction, https://www.kaggle.com/datasets/loveall/appliances-energy-prediction
4. 原作者公開程式：https://github.com/LuisM78/Appliances-energy-prediction-data
5. Data-Driven Modeling of Appliance Energy Usage, Energies (2023), https://www.mdpi.com/1996-1073/16/22/7536
6. statsmodels OLS Reference: https://www.statsmodels.org/stable/regression.html

附錄 A：15 組特徵集合與 VIF 摘要（僅 Training 計算）

Selector	k	Max VIF	VIF > 10	Median VIF
SelectKBest	14	26.36	3	5.51
SelectKBest	20	27.41	7	7.50
SelectKBest	25	404.83	12	9.99
RFE	14	364.74	9	12.72
RFE	20	384.16	11	11.52
RFE	25	404.83	12	9.99
SFS	14	366.27	6	7.74
SFS	20	383.22	6	6.59
SFS	25	404.83	12	9.99
Lasso	14	23.63	8	11.84
Lasso	20	27.57	9	7.49
Lasso	25	404.83	12	9.99
Permutation	14	382.45	5	8.07
Permutation	20	391.45	9	8.57
Permutation	25	404.83	12	9.99

附錄 B：45 組 Validation 指標完整表

以下數值僅來自 Validation，若需要精確的小數及被選特徵清單，參見 `5115056030_step4_outputs/validation_model_comparison.csv` 與 `selected_features.csv`。

Selector	k	模型	MAE	MSE	RMSE	R^2	Adjusted R^2
Permutation	14	LinearRegression	50.88	7175.3	84.71	0.1566	0.1526
Permutation	14	Ridge	51.34	7209.5	84.91	0.1526	0.1486
SFS	20	Lasso	46.50	7251.6	85.16	0.1477	0.1419
SFS	20	Ridge	47.02	7258.9	85.20	0.1468	0.1410
SFS	20	LinearRegression	47.30	7266.6	85.24	0.1459	0.1401
Permutation	20	LinearRegression	50.51	7266.6	85.24	0.1459	0.1401
Permutation	20	Ridge	50.87	7287.8	85.37	0.1434	0.1376
Permutation	14	Lasso	52.25	7288.4	85.37	0.1434	0.1393
Permutation	20	Lasso	51.48	7343.8	85.70	0.1368	0.1310
RFE	14	Ridge	53.40	7429.3	86.19	0.1268	0.1226
RFE	14	LinearRegression	52.85	7431.9	86.21	0.1265	0.1223
RFE	14	Lasso	54.70	7517.1	86.70	0.1165	0.1123
SelectKBest	20	LinearRegression	54.28	7520.8	86.72	0.1160	0.1100
SelectKBest	20	Ridge	54.24	7524.6	86.74	0.1156	0.1096
SelectKBest	20	Lasso	54.29	7539.5	86.83	0.1138	0.1078
Lasso	25	LinearRegression	54.58	7567.4	86.99	0.1106	0.1030

Selector	k	模型	MAE	MSE	RMSE	R^2	Adjusted R^2
Permutation	25	LinearRegression	54.58	7567.4	86.99	0.1106	0.1030
RFE	25	LinearRegression	54.58	7567.4	86.99	0.1106	0.1030
SFS	25	LinearRegression	54.58	7567.4	86.99	0.1106	0.1030
SelectKBest	25	LinearRegression	54.58	7567.4	86.99	0.1106	0.1030
RFE	20	LinearRegression	54.94	7585.8	87.10	0.1084	0.1023
Lasso	25	Ridge	55.07	7600.8	87.18	0.1066	0.0990
Permutation	25	Ridge	55.07	7600.8	87.18	0.1066	0.0990
RFE	25	Ridge	55.07	7600.8	87.18	0.1066	0.0990
SFS	25	Ridge	55.07	7600.8	87.18	0.1066	0.0990
SelectKBest	25	Ridge	55.07	7600.8	87.18	0.1066	0.0990
RFE	20	Ridge	55.43	7624.1	87.32	0.1039	0.0978
Lasso	14	LinearRegression	56.50	7653.1	87.48	0.1005	0.0962
Lasso	25	Lasso	55.58	7658.6	87.51	0.0998	0.0922
Permutation	25	Lasso	55.58	7658.6	87.51	0.0998	0.0922
RFE	25	Lasso	55.58	7658.6	87.51	0.0998	0.0922
SFS	25	Lasso	55.58	7658.6	87.51	0.0998	0.0922
SelectKBest	25	Lasso	55.58	7658.6	87.51	0.0998	0.0922
Lasso	14	Ridge	56.55	7660.9	87.53	0.0996	0.0953
Lasso	20	LinearRegression	56.00	7678.4	87.63	0.0975	0.0914
Lasso	20	Ridge	55.99	7681.8	87.65	0.0971	0.0910
Lasso	14	Lasso	56.77	7685.2	87.67	0.0967	0.0924
RFE	20	Lasso	56.04	7688.1	87.68	0.0964	0.0902
Lasso	20	Lasso	56.04	7690.7	87.70	0.0961	0.0899
SFS	14	Lasso	47.29	7787.6	88.25	0.0847	0.0803
SFS	14	Ridge	47.72	7803.5	88.34	0.0828	0.0784
SFS	14	LinearRegression	47.70	7808.8	88.37	0.0822	0.0778
SelectKBest	14	Lasso	53.34	7903.3	88.90	0.0711	0.0667
SelectKBest	14	Ridge	53.70	7936.8	89.09	0.0671	0.0627
SelectKBest	14	LinearRegression	53.80	7946.9	89.15	0.0660	0.0615

附錄 C：重現指令與產出目錄

```
pip install numpy pandas scipy matplotlib scikit-learn statsmodels joblib threadpoolctl
python 5115056030_hw2.py
# 若已完整驗證保存模型，可跳過重新選特徵：
python 5115056030_hw2.py --skip-modeling
```

輸入：`KAG_energydata_complete.csv` 放在主程式同層。輸出包含 `5115056030_step2_outputs/` 至 `5115056030_step6_outputs/`，其中保存完整統計表、特徵名單、VIF、殘差檢驗、CI/PI、PI coverage、兩個可載入 Pipeline 以及全部圖檔。原始環境特徵需保持訓練期間的欄位順序與量測單位；模型檔案只能從可信來源載入。完整研究過程另見 `5115056030_hw2_研究筆記_v6.md`。

GPT 完整對話過程

你說：

[https://www.kaggle.com/datasets/loveall/appliances-energy-prediction]
(https://www.kaggle.com/datasets/loveall/appliances-energy-prediction)
幫我評估是否是一個適合Multiple Linear Regression（多元線性回歸）的 Kaggle 題目
條件為：
13<Number of Features<4013<Number of Features<40
也就是 14–39 個輸入特徵，不包含 Target（預測目標）。
建議優先選擇連續數值預測（Regression）、可使用 sklearn.LinearRegression、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。
參考：特別注意Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 79 個原始特徵，不符合原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。
請嚴格遵守以下項目:
1.使用線性回歸 (Linear Regression) 模型進行預測。
可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
必須執行 特徵選擇 (Feature Selection) 與 模型評估 (Model Evaluation)。
結果部分需包含請提供預測圖(加上信賴區間或預測區間)

2.需要CRISP-DM 流程說明
Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment

3.AI協助要求
所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須匯出為 PDF
請使用 NotebookLM 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」

4 繳交內容
主程式：5115056030_hw2.py
報告檔：

-PDF，需包含以下內容：
-按照 CRISP-DM 說明的分析流程
-GPT 對話過程（pdfCrowd 匯出）
-NotebookLM 研究摘要
-網路上主流或更優解法之比較與說明
-以上檔案與資料夾請壓縮為學號命名的一個zip（例如 5115056030_hw2.zip）上傳。

重要:

文件說明

*CRISP-DM 流程完整且邏輯清楚
*包含 GPT 對話與 NotebookLM 摘要
*有明確說明資料集來源與研究脈絡

結果呈現

*模型正確可執行，具特徵選擇與評估
*結果合理、美觀且具有說服力
*呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

補充參考:

For any selected dataset, We can complete:
1. Business Understanding: Define the continuous prediction target.
2. Data Understanding: Verify sample size, feature count, missing values and correlations.
3. Data Preparation: Train/test split, missing-value handling and categorical encoding.
4. Modeling: Train LinearRegression, Ridge and Lasso.
5. Evaluation: Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.
6. Deployment: Predict new samples and explain the model.
For Feature Selection, compare SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance, selecting 14, 20, 25 or 30 features using training data only.
My first choice is Predict the Flood, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.

我們先一步一步討論.step by step.然後先慢慢整理成一個md檔

處理時間為 2m 30s

ChatGPT 說：

Step 1：Appliances Energy Prediction 資料集適用性評估

符合 14–39 個原始輸入特徵的限制

初步結論：我推薦使用這個資料集完成多元線性回歸作業。 它有足夠的特徵、明確的連續預測目標、真實的能源應用背景，還有原始學術論文可以引用。

不過，它有一個值得注意的難點：**這是時間序列資料，而且多元線性回歸可能無法充分解釋其非線性變化。** 這反而可以成為報告的研究重點。

1. 資料集基本資訊



Appliances Energy Prediction

家庭電器能源消耗預測

利用室內溫濕度、室外氣象及照明耗電資料，預測家用電器的能源消耗。

Kaggle 資料集 ↗ · UCI 原始資料 ↗

19,735	27	Regression
資料筆數	數值輸入特徵	任務類型

資料來自比利時一棟低能耗住宅，約每 10 分鐘記錄一次，涵蓋約 4.5 個月。UCI 確認資料沒有缺失值，原始檔案共有 29 欄，包括日期與預測目標。 UCI 機器學… +1

2. 最重要的：特徵數真的符合嗎？

符合，但要釐清 28、27、25 這三個數字的差別。

計算方式	特徵數	結果
原始輸入欄位，包含 `date`	28	符合
排除 `date` ，保留數值欄位	27	符合
再排除 `rv1` 、 `rv2`	25	符合
另外使用 Feature Selection 選取	14–25	符合

其中 `Appliances` 是預測目標，不計入輸入特徵。

`rv1` 和 `rv2` 是資料集作者刻意加入的隨機變數，用於測試模型能否排除無預測價值的特徵。這很適合拿來展示 Feature Selection。 doi UCI Machine Le...

3. 對照老師作業要求

作業要求	適用性	評估
14–39 個特徵	✓	原始數值輸入有 27 個
連續數值預測	✓	預測 Appliances（Wh）
`sklearn.LinearRegression`	✓	可直接使用
Feature Selection	✓	可比較 RFE、SelectKBest、Lasso
MSE、RMSE、R^2	✓	都可計算
預測圖與預測區間	✓	可用 OLS 推論或 Bootstrap
五大回歸假設檢驗	⚠	可以檢驗，但不一定滿足
CRISP-DM 六階段	✓	真實應用情境很明確
NotebookLM 文獻比較	✓	有原始論文與公開研究
Kaggle 名次	⊖	一般資料集，沒有固定競賽排名

這份資料集的優勢，是不必為了湊特徵數而做大量 One-Hot Encoding，也不需要像 House Prices 那樣從 79 個原始特徵中先縮減。

4. 要特別注意的三個問題

第一，時間序列不能隨便打散。 我建議主要實驗採用依時間先後切分的 Training、Validation、Test，而不是單純隨機 80/20。這樣比較符合預測未來耗電量的實際情境。

第二，溫度與濕度可能存在共線性。 例如不同房間的室溫可能高度相關，需要使用 VIF 分析。這正好符合五大回歸假設檢驗的要求。

第三，R^2 可能不高。 家電耗電會受到開關、使用行為等因素影響，而這些資訊未必完整包含在資料中。即使模型表現普通，也可以透過殘差分析與模型比較，提出有說服力的結果。原始論文也研究了特徵排名與不同預測模型。 E ScienceDirect

5. 已建立 Markdown 第一版

5115056030_hw2_研究筆記_v1.md

已整理資料集評估、CRISP-DM 六階段、研究流程圖、實驗規劃與文獻來源。

下載 Markdown 初稿 ↗

這一版沒有虛構模型準確率，也沒有假裝已經完成 NotebookLM 研究。後續會把實際分析結果持續整合進這份 MD。

6. 下一步：真正檢查資料

建議下一輪從 **Step 2：Data Understanding** 開始，先讀取 CSV 並完成以下工作：

1. 確認 19,735 筆、29 欄及每個欄位的意義。
2. 檢查缺失值、重複值與異常值。
3. 分析 `Appliances` 的數值分布。
4. 繪製特徵相關性矩陣。
5. 檢查 `rv1` 、 `rv2` 與其他特徵的關係。

這一步會決定我們如何設計 Feature Selection，以及後續 Linear Regression 是否需要額外處理資料。

我的建議是先確定資料特性，再決定模型設計，不要直接套用網路上的程式。

繼續 Step 2：資料探索

你說：

繼續 Step 2：Data Understanding。請帶我逐步檢查 Appliances Energy Prediction 的所有欄位、特徵數、缺失值、分布與相關性，並持續更新 Markdown 研究筆記。

處理時間為 2m 32s

ChatGPT 說：

Step 2：Data Understanding（資料理解）

這次先不進入模型訓練，專心完成 CRISP-DM 第二階段，並持續更新 Markdown 研究筆記。

一、確認資料集結構

根據 UCI 官方資料集 ↗，目前確認：

19,735	29	27
樣本數	原始欄位數	數值輸入特徵

原始 29 欄包含 `date` 、目標 `Appliances` 與 27 個數值特徵，因此完全符合老師指定的 14–39 個輸入特徵。 UCI 機器學習資...

二、所有欄位的分類

分類	欄位	數量
時間	`date`	1
預測目標	`Appliances`	1
照明耗電	`lights`	1
各位置溫度	`T1` – `T9`	9
各位置相對濕度	`RH_1` – `RH_9`	9
室外氣象	`T_out`, `Press_mm_hg`, `RH_out`, `Windspeed`, `Visibility`, `Tdewpoint`	6
隨機控制變數	`rv1`, `rv2`	2

其中 `T6` 、 `RH_6` 是建物北側的室外感測器資料，不是室內資料。

三、我們要檢查什麼？

1. 資料品質

檢查欄位型態、Missing Values、重複資料、重複時間，以及時間間隔是否正常。

2. Target 分布

分析 `Appliances` 的平均值、中位數、標準差、最大最小值和離群值，繪製 Histogram、Boxplot、時間序列圖。

3. 相關性分析

使用 Pearson Correlation，觀察各個特徵與 `Appliances` 的線性關係，也檢查特徵之間是否高度相關。

相關係數的概念是：

- 接近 +1：正向線性關係強。
- 接近 −1：負向線性關係強。
- 接近 0：線性關係弱，但不代表不存在非線性關係。

四、本次完成的檔案

更新後的 Markdown 研究筆記

保留 Step 1，新增 Step 2 完整欄位說明、資料檢查方法及實驗注意事項。

下載 MD 筆記 ↗

Python 資料探索程式

可輸出統計 CSV、JSON 與五張分析圖。

下載 Step 2 Python ↗

在電腦上執行

先從 UCI ↗ 或 Kaggle ↗ 下載 `energydata_complete.csv`，與程式放在同一資料夾，接著執行：

```
pip install pandas numpy matplotlib
python 5115056030_step2_data_understanding.py --csv energydata_complete.csv
```

會產生：

- `column_profile.csv`：各欄缺失值與型態。
- `numeric_describe.csv`：描述統計。
- `target_correlations.csv`：特徵與目標的相關係數。
- `pearson_corr_matrix.csv`：完整相關性矩陣。
- `summary.json`：資料品質與重要統計結果。
- 五張 PNG 圖：分布、箱型圖、時間變化和相關性。

目前的限制：已完成官方資料核對與可執行程式，但還沒有取得完整 CSV 來執行真實統計。因此，缺失值的實測、相關係數排名與離群值比例均尚未確認。

五、接下來建議

先完成 Step 2 的真實數據分析，再進入 Step 3：Data Preparation。

請直接上傳 `energydata_complete.csv`。 我就可以使用真實資料替你計算所有統計結果、檢視相關性圖，並將具體數字和分析結論更新進目前這份 Markdown，而不是只提供分析程式。

你說：

KAG Energydata Complete Selected Columns

	date	Appliances	lights	T1	RH_1

已停止思考

你說：

KAG_energydata_...
試算表

處理時間為 8m 55s

ChatGPT 說：

Step 2：Data Understanding — 真實資料分析

這次已成功讀取你上傳的完整 `KAG_energydata_complete.csv`，並且完成第一輪數值檢查。

實際資料筆數	數值輸入特徵	缺失值
19,735	27	0

1. 資料品質檢查結果

檢查項目	實測結果
原始資料大小	19,735 × 29
預測目標	`Appliances`
缺失值	0
完全重複資料	0 筆
重複時間戳記	0 筆
觀測期間	2016/01/11–2016/05/27

取樣間隔	每 10 分鐘
時間間隔是否連續	是，全部 19,734 個間隔均為 10 分鐘
常數數值欄位	0 個

這表示資料相當完整，**不需要為了缺失值進行平均值填補或刪除樣本**。

2. Target：Appliances 的真實分布

統計項目	實際數值
最小值	10 Wh
第一四分位數 Q1	50 Wh
中位數 Median	60 Wh
平均值 Mean	97.69 Wh
第三四分位數 Q3	100 Wh
最大值	1,080 Wh
標準差	102.52 Wh
第 95 百分位數	330 Wh
IQR 判定高耗電異常值	2,138 筆（10.83%）

有一個重要發現：**平均值 97.69 Wh 明顯高於中位數 60 Wh**，代表少量高耗電紀錄拉高了整體平均值，分布具有右偏特徵。

依 IQR 方法找到的 2,138 筆資料，不代表一定是錯誤資料。它們可能反映洗衣機、烤箱或其他家電運作時的正常高耗電現象，因此現階段不建議直接刪除。

3. 發現完全重複的特徵

實際檢查發現：

`rv1` 與 `rv2` 在全部 19,735 筆資料中完全相同。

這兩欄的 Pearson 相關係數為 **1.0000**，屬於完全共線性。

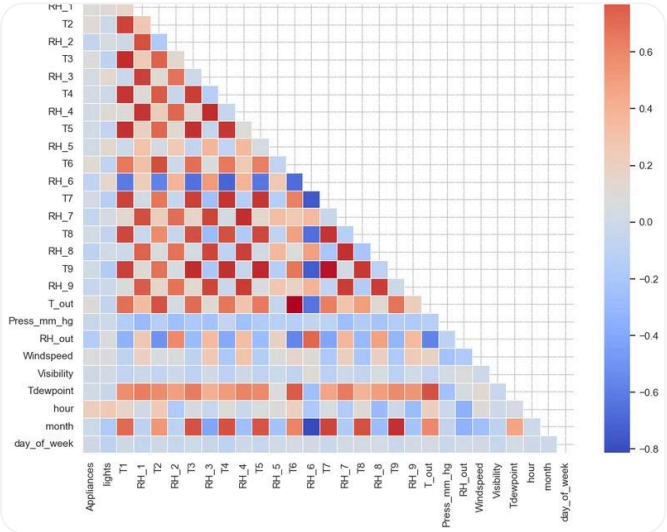
對後續多元線性回歸而言，這是很好的研究案例。若兩欄同時進入模型，會造成設計矩陣的線性相依，使個別迴歸係數無法唯一識別。

因此可在資料準備階段先刪掉其中一欄，再進一步討論是否保留另一個隨機控制變數。即使移除 `rv1` 、 `rv2` ，仍然保有 **25 個數值輸入特徵**，完全符合老師要求。

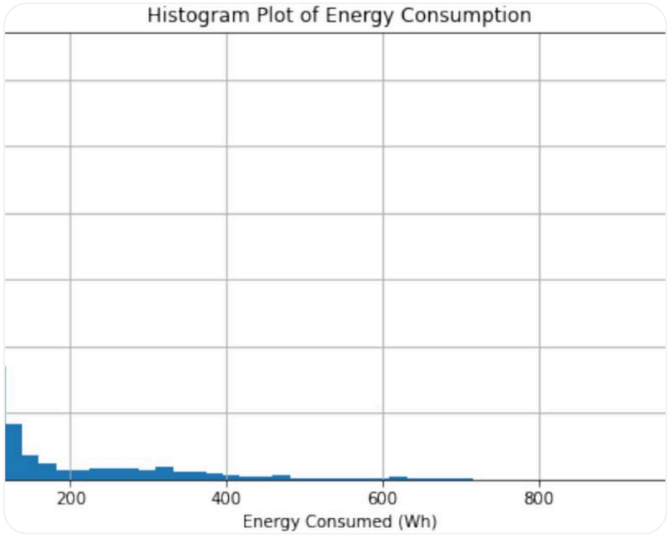
4. 真實相關性分析結果

以下是與 `Appliances` 線性相關程度最高的五個輸入特徵。

排名	特徵	Pearson r
1	`lights`	+0.1973
2	`RH_out`	−0.1523
3	`T2`	+0.1201
4	`T6`	+0.1176
5	`T_out`	+0.0992



相關係數矩陣示意



右偏分布示意

這些是示意圖，真正從你的 CSV 計算的圖表請使用下方檔案：

查看實測相關性熱圖 ↗ · 查看實測耗電量分布圖 ↗

其中， `T6` 與 `T_out` 的相關係數達到 **0.9748**；在 27 個輸入特徵的兩兩組合中，共有 36 對的相關係數絕對值超過 0.8。

這代表日後需要認真處理多重共線性。另一方面，各個特徵與 Target 的單獨線性相關性偏弱，也讓這份資料很適合研究多元線性回歸的能力與限制。

5. 更新完成的研究檔案

Step 2 實測成果包

包含更新後的 MD、Python 程式、7 張實測圖表，以及 8 份 JSON/CSV 統計檔。

下載完整成果 ZIP ↗

研究筆記 v2

下載 Markdown ↗

可重現資料分析程式

下載 Python ↗

MD 已經保留原先的選題評估與 CRISP-DM 規劃，並新增 29 個原始欄位的完整數值範圍、相關係數、資料品質統計、時間特性及可放進正式報告的 Data Understanding 結論。

目前尚未進行模型訓練，所以沒有虛構 R^2、RMSE 或預測區間。

6. 下一步：Step 3 — Data Preparation

在正式寫 `LinearRegression` 前，有一個研究方向值得先確定：

你希望模型預測什麼？

- **A. 預測目前這 10 分鐘的家電耗電量（推薦）** — 使用同時間記錄的溫度、濕度、照明等資訊估計耗電量。適合多元線性回歸課堂作業。
- **B. 預測下一個 10 分鐘的耗電量** — 需要處理特徵和預測目標的時間差，必須避免使用未來才會取得的資料。

確認方向，繼續 Step 3

04_correlation_heatmap.png
圖像

01_target_histogram.png
圖像

你說：

繼續 Step 3：Data Preparation。使用 A 方案：同一時間點的家電耗電量估計。請逐步說明資料切分、重複欄位處理、特徵數控制，並更新 Markdown。

處理時間為 8m 17s

ChatGPT 說：

Step 3：Data Preparation（資料準備）

這次採用 **A 方案：同一時間點家電耗電量估計**，並延續 Step 2 使用的完整資料集 `KAG_energydata_complete.csv`。

這個階段的重點不是把資料送進模型就好，而是確保後續的 `LinearRegression`、Feature Selection 和模型評估都不會發生 Data Leakage（資料洩漏）。

1. 確定輸入 X 與預測目標 y

我們要建立的數學模型是：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中：

- y：`Appliances`，實際家電耗電量（Wh）。
- $\hat{y}$：多元線性回歸估計的家電耗電量。
- $x_1, \ldots, x_p$：溫度、濕度、照明及氣象資料。
- p：模型使用的特徵數，預計比較 14、20、25。
- β_0：截距，$\beta_1, \ldots, \beta_p$：回歸係數。

這是同時段估計，不是未來耗電量預測。 例如使用 14:00–14:10 的環境與照明紀錄，估計同一時段的 `Appliances`。因此 `lights` 可以作為輸入，但系統必須先取得該時段的照明資料，才能估計耗電量。

2. Train / Validation / Test 資料切分

我選擇依照日期排序的 70% / 15% / 15% 切分，並已實際使用你的 CSV 計算。

Train 70% | Val 15% | Test 15%

13,814	2,960	2,961
Training	Validation	Testing

資料集	起始時間	結束時間
Training	2016/01/11 17:00	2016/04/16 15:10
Validation	2016/04/16 15:20	2016/05/07 04:30
Testing	2016/05/07 04:40	2016/05/27 18:00

為什麼不用一般的 `train_test_split(shuffle=True)` ？

因為 Step 2 已經發現，耗電量在相鄰 10 分鐘的自相關係數約為 **0.753**。若隨機切分，某筆測試資料相鄰的時間點可能出現在訓練集，容易讓評估過於樂觀。

依時間切分更適合檢驗模型在較晚觀測期間的泛化能力。

3. 特徵數控制

原始資料有 27 個數值輸入特徵，且 `rv1` 、 `rv2` 完全相同。

我建議將兩者都排除。這是根據資料來源已知的隨機控制變數身分及欄位重複性所做的事前決定，而不是利用測試集表現選擇欄位。

階段	輸入特徵數
原始數值輸入	27
移除完全重複的 `rv2`	26
再移除無實際預測意義的 `rv1`	25
Step 4：比較 Feature Selection	14、20、25

因此，**25 個特徵是我們正式建模的起始候選集合**。後續仍會實際執行 Feature Selection，不會因為已符合老師的特徵數限制，就省略這個必要步驟。

4. 資料切分後的新發現

實際切分後，三組資料的分布並不完全相同：

統計項目	Train	Validation	Test
平均耗電量（Wh）	98.78	93.42	96.93
標準差（Wh）	106.86	92.25	90.89
第 95 百分位數（Wh）	340	290	280
`lights = 0` 比例	73.28%	85.00%	88.25%

這表示較晚的觀測期間存在一定程度的**資料分布變化（Distribution Shift）**。即使 Training 的模型表現良好，也不代表它在 Validation 或 Test 期間會有相同準確率。

實際 CSV 產生的時間切分圖，背景區塊依序代表 Train、Validation 與 Test。

5. Markdown v3 與程式已更新

研究筆記 v3 — Markdown

包含 Step 1–3、實測資料、切分方法、特徵數控制、資料洩漏防範與正式報告段落。

下載 Markdown v3 ↗

Step 3 Python 程式

可以重新產生三份資料切片、統計表與兩張圖表。

下載 Python ↗

Step 1–3 完整階段成果

包含 MD、原始 CSV、Step 2 與 Step 3 程式、統計和所有圖表。

下載完整 ZIP ↗

6. 下一步：Step 4 — Modeling & Feature Selection

目前已完成 **Data Preparation，但還沒有真正執行 Feature Selection 或訓練模型**。

下一階段建議先用 25 個候選特徵建立完整 `LinearRegression` Baseline，接著在訓練資料內比較 `SelectKBest` 、RFE 等方法，選出 14 或 20 個特徵。用 Validation 的 MAE、RMSE 和 R^2 決定模型方案，最後才開啟 Test 進行正式評估。

我們也要特別檢查高度相關的溫度、濕度變數，避免係數因多重共線性而不穩定。

這樣循序完成 Step 4、Step 5，最後才能讓報告中的特徵選擇、模型指標、五大假設檢驗與預測區間都有實際數據支撐。

如果你願意，我可以：

- 繼續檢查缺失值與異常狀況
- 執行特徵相關性分析與視覺化
- 開始特徵選擇與建模準備

你說：

KAG Energydata Complete Selected Columns

	date	Appliances	lights	T1	RH_1

已停止思考

你說：

KAG_energydata_...
試算表

處理時間為 8m 55s

ChatGPT 說：

Step 2：Data Understanding — 真實資料分析

這次已成功讀取你上傳的完整 `KAG_energydata_complete.csv` ，並且完成第一輪數值檢查。

實際資料筆數	數值輸入特徵	缺失值
19,735	27	0

1. 資料品質檢查結果

檢查項目	實測結果
原始資料大小	19,735 × 29
預測目標	`Appliances`
缺失值	0
完全重複資料	0 筆
重複時間戳記	0 筆
觀測期間	2016/01/11–2016/05/27
取樣間隔	每 10 分鐘
時間間隔是否連續	是，全部 19,734 個間隔均為 10 分鐘

常數數值欄位	0 個

這表示資料相當完整，**不需要為了缺失值進行平均值填補或刪除樣本**。

2. Target：Appliances 的真實分布

統計項目	實際數值
最小值	10 Wh
第一四分位數 Q1	50 Wh
中位數 Median	60 Wh
平均值 Mean	97.69 Wh
第三四分位數 Q3	100 Wh
最大值	1,080 Wh
標準差	102.52 Wh
第 95 百分位數	330 Wh
IQR 判定高耗電異常值	2,138 筆（10.83%）

有一個重要發現：**平均值 97.69 Wh 明顯高於中位數 60 Wh**，代表少量高耗電紀錄拉高了整體平均值，分布具有右偏特徵。

依 IQR 方法找到的 2,138 筆資料，不代表一定是錯誤資料。它們可能反映洗衣機、烤箱或其他家電運作時的正常高耗電現象，因此現階段不建議直接刪除。

3. 發現完全重複的特徵

實際檢查發現：

`rv1` 與 `rv2` 在全部 19,735 筆資料中完全相同。

這兩欄的 Pearson 相關係數為 **1.0000**，屬於完全共線性。

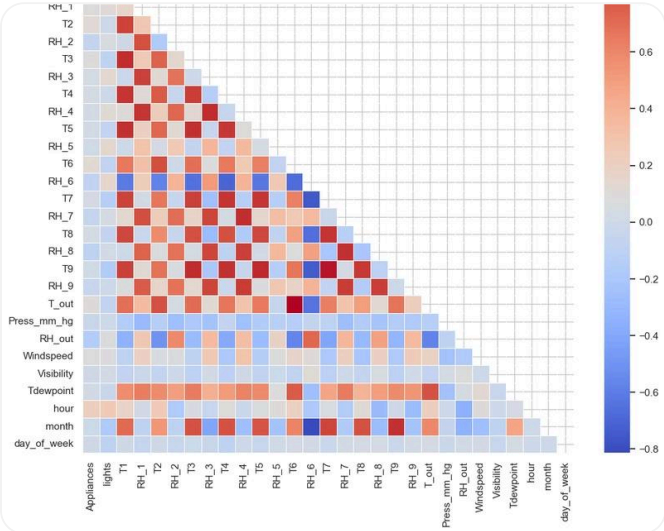
對後續多元線性回歸而言，這是很好的研究案例。若兩欄同時進入模型，會造成設計矩陣的線性相依，使個別迴歸係數無法唯一識別。

因此可在資料準備階段先刪掉其中一欄，再進一步討論是否保留另一個隨機控制變數。即使移除 `rv1` 、 `rv2` ，仍然保有 **25 個數值輸入特徵**，完全符合老師要求。

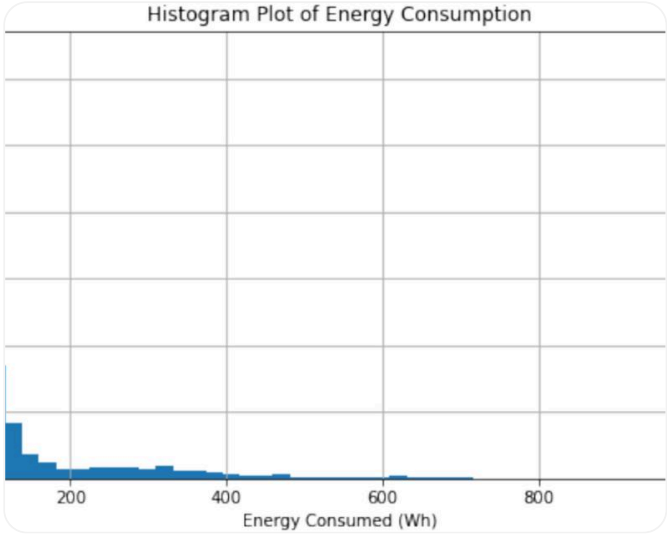
4. 真實相關性分析結果

以下是與 `Appliances` 線性相關程度最高的五個輸入特徵。

排名	特徵	Pearson r
1	`lights`	+0.1973
2	`RH_out`	−0.1523
3	`T2`	+0.1201
4	`T6`	+0.1176
5	`T_out`	+0.0992



相關係數矩陣示意



右偏分布示意

這些是示意圖，真正從你的 CSV 計算的圖表請使用下方檔案：

查看實測相關性熱圖 ↗ · 查看實測耗電量分布圖 ↗

其中， `T6` 與 `T_out` 的相關係數達到 **0.9748**；在 27 個輸入特徵的兩兩組合中，共有 36 對的相關係數絕對值超過 0.8。

這代表日後需要認真處理多重共線性。另一方面，各個特徵與 Target 的單獨線性相關性偏弱，也讓這份資料很適合研究多元線性回歸的能力與限制。

5. 更新完成的研究檔案

Step 2 實測成果包

包含更新後的 MD、Python 程式、7 張實測圖表，以及 8 份 JSON/CSV 統計檔。

下載完整成果 ZIP ↗

研究筆記 v2

下載 Markdown ↗

可重現資料分析程式

下載 Python ↗

MD 已經保留原先的選題評估與 CRISP-DM 規劃，並新增 29 個原始欄位的完整數值範圍、相關係數、資料品質統計、時間特性及可放進正式報告的 Data Understanding 結論。

目前尚未進行模型訓練，所以沒有虛構 R^2、RMSE 或預測區間。

6. 下一步：Step 3 — Data Preparation

在正式寫 `LinearRegression` 前，有一個研究方向值得先確定：

你希望模型預測什麼？

- **A. 預測目前這 10 分鐘的家電耗電量（推薦）** — 使用同時間記錄的溫度、濕度、照明等資訊估計耗電量。適合多元線性回歸課堂作業。
- **B. 預測下一個 10 分鐘的耗電量** — 需要處理特徵和預測目標的時間差，必須避免使用未來才會取得的資料。

確認方向，繼續 Step 3

04_correlation_heatmap.png
圖像

01_target_histogram.png
圖像

你說：

繼續 Step 3：Data Preparation。使用 A 方案：同一時間點的家電耗電量估計。請逐步說明資料切分、重複欄位處理、特徵數控制，並更新 Markdown。

處理時間為 8m 17s

ChatGPT 說：

Step 3：Data Preparation（資料準備）

這次採用 **A 方案：同一時間點家電耗電量估計**，並延續 Step 2 使用的完整資料集 `KAG_energydata_complete.csv`。

這個階段的重點不是把資料送進模型就好，而是確保後續的 `LinearRegression`、Feature Selection 和模型評估都不會發生 Data Leakage（資料洩漏）。

1. 確定輸入 X 與預測目標 y

我們要建立的數學模型是：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中：

- y：`Appliances`，實際家電耗電量（Wh）。
- $\hat{y}$：多元線性回歸估計的家電耗電量。
- $x_1, \ldots, x_p$：溫度、濕度、照明及氣象資料。
- p：模型使用的特徵數，預計比較 14、20、25。
- β_0：截距，$\beta_1, \ldots, \beta_p$：回歸係數。

這是同時段估計，不是未來耗電量預測。 例如使用 14:00–14:10 的環境與照明紀錄，估計同一時段的 `Appliances`。因此 `lights` 可以作為輸入，但系統必須先取得該時段的照明資料，才能估計耗電量。

2. Train / Validation / Test 資料切分

我選擇依照日期排序的 70% / 15% / 15% 切分，並已實際使用你的 CSV 計算。

Train 70% | Val 15% | Test 15%

13,814	2,960	2,961
Training	Validation	Testing

資料集	起始時間	結束時間
Training	2016/01/11 17:00	2016/04/16 15:10
Validation	2016/04/16 15:20	2016/05/07 04:30
Testing	2016/05/07 04:40	2016/05/27 18:00

為什麼不用一般的 `train_test_split(shuffle=True)` ？

因為 Step 2 已經發現，耗電量在相鄰 10 分鐘的自相關係數約為 **0.753**。若隨機切分，某筆測試資料相鄰的時間點可能出現在訓練集，容易讓評估過於樂觀。

依時間切分更適合檢驗模型在較晚觀測期間的泛化能力。

3. 特徵數控制

原始資料有 27 個數值輸入特徵，且 `rv1` 、 `rv2` 完全相同。

我建議將兩者都排除。這是根據資料來源已知的隨機控制變數身分及欄位重複性所做的事前決定，而不是利用測試集表現選擇欄位。

階段	輸入特徵數
原始數值輸入	27
移除完全重複的 `rv2`	26
再移除無實際預測意義的 `rv1`	25
Step 4：比較 Feature Selection	14、20、25

因此，**25 個特徵是我們正式建模的起始候選集合**。後續仍會實際執行 Feature Selection，不會因為已符合老師的特徵數限制，就省略這個必要步驟。

4. 資料切分後的新發現

實際切分後，三組資料的分布並不完全相同：

統計項目	Train	Validation	Test
平均耗電量（Wh）	98.78	93.42	96.93
標準差（Wh）	106.86	92.25	90.89
第 95 百分位數（Wh）	340	290	280
`lights = 0` 比例	73.28%	85.00%	88.25%

這表示較晚的觀測期間存在一定程度的**資料分布變化（Distribution Shift）**。即使 Training 的模型表現良好，也不代表它在 Validation 或 Test 期間會有相同準確率。

實際 CSV 產生的時間切分圖，背景區塊依序代表 Train、Validation 與 Test。

5. Markdown v3 與程式已更新

研究筆記 v3 — Markdown

包含 Step 1–3、實測資料、切分方法、特徵數控制、資料洩漏防範與正式報告段落。

下載 Markdown v3 ↗

Step 3 Python 程式

可以重新產生三份資料切片、統計表與兩張圖表。

下載 Python ↗

Step 1–3 完整階段成果

包含 MD、原始 CSV、Step 2 與 Step 3 程式、統計和所有圖表。

下載完整 ZIP ↗

6. 下一步：Step 4 — Modeling & Feature Selection

目前已完成 **Data Preparation，但還沒有真正執行 Feature Selection 或訓練模型**。

下一階段建議先用 25 個候選特徵建立完整 `LinearRegression` Baseline，接著在訓練資料內比較 `SelectKBest` 、RFE 等方法，選出 14 或 20 個特徵。用 Validation 的 MAE、RMSE 和 R^2 決定模型方案，最後才開啟 Test 進行正式評估。

我們也要特別檢查高度相關的溫度、濕度變數，避免係數因多重共線性而不穩定。

這樣循序完成 Step 4、Step 5，最後才能讓報告中的特徵選擇、模型指標、五大假設檢驗與預測區間都有實際數據支撐。

你說：

「請繼續進行 **Step 4：Feature Selection & Modeling（特徵選擇與建模）**，並延續使用上傳的真實資料 `KAG_energydata_complete.csv` 與 Step 3 切分好的 Train / Validation / Test。
在這一步，請幫我實作並注意以下要求：

1. **前處理防洩漏**：請僅使用 Training set 進行 `StandardScaler` 的 `fit` ，再對 Train / Val / Test 進行 `transform` 。
2. **五種特徵選擇方法比較（僅在 Train 上進行）**：針對 25 個候選特徵，請比較 `SelectKBest (f_regression)` 、 `RFE` 、 `Sequential Feature Selection (SFS)` 、 `Lasso` 以及

`Permutation Importance` ，並比較選取 **14、20、25 個特徵**的結果，列出被選中的特徵清單與各組的 **VIF（多重共線性檢查）**。

3. **模型訓練與評估指標**：對上述選出的特徵組合，分別訓練 `LinearRegression` 、 `Ridge` 、 `Lasso` ，並在 Validation set（以及最終最佳組合在 Test set）上計算 **MAE、MSE、RMSE、R^2 與 Adjusted R^2**，整理成清楚的比較表格。
4. **延伸實驗（呼應作業要求的 Auto Regression）**：由於純環境變數與耗電量的線性相關性偏弱，除了上述 25 個純環境特徵的標準多元線性回歸外，請額外做一個小對照實驗：嘗試加入前幾個時間點的滯後項（Lag features，即 Auto Regression 概念）並控制總特徵數同樣在 14–39 之間，比較加入前後 R^2 與 RMSE 的變化，作為報告中的分析亮點。
5. 請根據真實執行結果，更新 **Markdown 研究筆記至 v4**，並提供對應的 Step 4 Python 腳本與圖表。」

處理時間為 13m 10s

ChatGPT 說：

Step 4：Feature Selection & Modeling — 實測結果

已使用你的 `KAG_energydata_complete.csv` 完成五種特徵選擇、三種線性回歸模型，以及加入滯後項的延伸實驗。沿用 Step 3 的 13,814 筆 Training、2,960 筆 Validation、2,961 筆 Test。

一、模型比較的主要發現

Validation RMSE 最佳組合（45 組比較）

84.71 Wh

Permutation Importance + 14 Features + LinearRegression

Validation R^2	Test R^2	Test RMSE
0.1566	**0.0366**	**89.20 Wh**

這個結果值得注意：**Validation 的 R^2 約為 15.66%，但 Test 只剩約 3.66%。** 它說明即使已經避免資料洩漏、正確執行特徵選擇，多元線性回歸對不同時間區段的泛化能力仍可能有限。

Validation 最佳前五組

特徵選擇	數量	模型	RMSE (Wh)	R^2
Permutation Importance	14	LinearRegression	84.71	0.1566

Permutation Importance	14	Ridge	84.91	0.1526
SFS	20	Lasso	85.16	0.1477
SFS	20	Ridge	85.20	0.1468
SFS	20	LinearRegression	85.24	0.1459

排名依 Validation RMSE 決定，而不是根據 Test 結果選模型。

二、Auto Regression 延伸實驗

加入前 10、20、30 分鐘的實際耗電量（ `lag1` 、 `lag2` 、 `lag3` ）後，採用同樣的 `LinearRegression` ，比較原本 25 特徵與加入滯後項後的 28 特徵。

Test R^2 比較

25 個環境特徵

0.0570

25 個環境特徵 + 3 個 Lag

0.5435

兩組均使用同一批對齊後的測試資料，共 2,961 筆。

加入滯後項後，Test RMSE 從 **88.25 Wh 降至 61.40 Wh**，約降低 30.4%。

這個改善有明確前提：估計當期耗電量時，必須已經取得之前三個時間點的真實耗電量。它適合連續更新的估計情境，**不是在不知道過去實際耗電量時直接預測未來**。

三、VIF 多重共線性檢查

VIF 已針對全部 15 組特徵集合，**只使用 Training 資料**進行計算。

特徵組合	最大 VIF	VIF > 10 的特徵數
SelectKBest，14 特徵	26.36	3
Lasso，14 特徵	23.63	8
SFS，20 特徵	383.22	6
Permutation Importance，14 特徵（最佳 Validation）	382.45	5
完整 25 特徵	404.83	12

這裡有兩個重要結論：

- **預測能力最好，不代表共線性最低。** Validation 最佳模型仍有嚴重的共線性風險。
- VIF 高不一定讓預測失效，但會增加個別迴歸係數解釋的不穩定性。

全部 15 組的特徵清單、每個特徵的 VIF，均已放入 Markdown v4 和 CSV 明細。

四、完成的檔案

Step 4 完整實測成果 ZIP

包含原始 CSV、Markdown v4、完整 Python 程式、所有指標、特徵清單、VIF、6 張圖與已訓練模型。

下載完整成果包 ↗

Markdown 研究筆記 v4

保留 Step 1–3，新增 Step 4 實測結果、45 組比較、全部 VIF 表格與可放入報告的 Modeling 章節。

下載 Markdown v4 ↗

Step 4 Python 完整程式

已實際執行並驗證，可直接重新產生所有模型、統計與圖表。

下載 Python ↗

重要的個別表格也可以直接取得：45 組模型比較 CSV ↗、特徵選擇清單 ↗、VIF 完整明細 ↗。

圖表包括 Validation RMSE 排名 ↗、VIF 比較 ↗、最終 Test 預測圖 ↗ 與 Auto Regression 比較圖 ↗。

五、下一階段的研究重點

Step 4 已完成實際建模、特徵選擇及評估。接下來的 **Step 5：Evaluation** 應著重：

- 五大回歸假設：線性、誤差獨立、等變異、殘差常態及多重共線性。
- 殘差圖、Q–Q Plot、Durbin–Watson、Breusch–Pagan 與 VIF。
- 老師要求的 **95% 信賴區間或預測區間**，並解釋時間自相關對區間可靠性的影響。

目前這份研究已有一個很有說服力的分析方向：**比較純環境特徵多元線性回歸的限制，以及加入歷史耗電資訊後的改善，同時檢驗這些改善是否建立在合理的資料取得與統計假設上。**

這會是後續完整 CRISP-DM 報告的核心。

validation_model_comparison.csv
試算表

selected_features.csv
試算表

vif_details.csv
試算表

再顯示 4 個

你說：

「請繼續進行 **Step 5：Evaluation（模型深入評估、五大回歸假設檢驗與預測區間視覺化）**，延續 Step 4 的最佳特徵子集模型，並同時比較『方案 A：純環境特徵多元線性回歸』與『方案 B：加入滯後項之 Auto Regression 線性回歸』。
在這一步，請幫我實作並產出以下內容：

1. **五大回歸假設完整檢驗（量化指標 + 視覺化圖表）**：
    - **線性關係（Linearity）**：繪製 Residuals vs. Fitted Values（殘差對預測值圖），檢視是否有非線性趨勢。
    - **誤差獨立性（Independence）**：計算 **Durbin–Watson (DW)** 統計量並繪製殘差 ACF（自相關函數）圖，特別比較『純環境模型』與『Auto Regression 模型』在加入 Lag 特徵後，DW 值是否顯著改善並接近 2.0。
    - **誤差等變異性（Homoscedasticity）**：執行 **Breusch–Pagan 檢定**（列出 LM 統計量與 p-value），觀察殘差是否隨預測值變大而呈現漏斗狀擴散。

- **殘差常態性（Normality）**：繪製殘差 Histogram 與 **Q–Q Plot**，並計算殘差的偏態（Skewness）、峰度（Kurtosis）與 Jarque–Bera / Omnibus 檢定結果。
- **無多重共線性（No Multicollinearity）**：整理最終選取特徵組合的 **VIF（變異數膨脹因子）** 分布與最大值，驗證特徵選擇是否成功降低共線性。

2. **預測結果圖（含 95% 信賴區間 CI 與 95% 預測區間 PI）**：
   - 利用 OLS 解析公式（或 `statsmodels get_prediction().summary_frame(alpha=0.05)`）計算 Test set 上的點預測、95% 信賴區間（Confidence Interval of Mean）與 95% 預測區間（Prediction Interval）。
   - 為了讓圖表清晰美觀，除了全測試集概覽外，請務必繪製 **測試集局部放大視窗（例如挑選連續 72 小時 / 432 個時間點）**的預測曲線圖，清楚標示實際值（Actual）、預測值（Predicted）、95% CI 陰影帶與 95% PI 陰影帶。
   - 計算測試集實際值落入 95% 預測區間的涵蓋率（Coverage Rate），並深入分析：為何時間自相關、異質變異與右偏尖峰會影響傳統 OLS 預測區間的可靠性（例如低負荷時區間過寬甚至下界小於 0、高負荷尖峰時超出上界）。
3. 請將上述所有實測統計表格、五大假設診斷結論與圖表更新至 **Markdown 研究筆記 v5**，並提供對應的 Step 5 Python 程式與圖檔。」

處理時間為 12m 20s

ChatGPT 說：

Step 5：Evaluation — 評估設計確認

這次會固定 Step 4 的模型，不再根據 Test 結果重新挑選特徵或調整參數。

模型	輸入特徵	Step 4 Test R^2	Test RMSE
A：最佳環境模型	14	0.0366	89.20 Wh
環境模型對照組	25	0.0570	88.25 Wh
B：環境 + 3 個 Lag	28	0.5435	61.40 Wh

有兩件事需要特別區分：

第一，95% CI 是針對「條件平均耗電量」的不確定性；95% PI 才是針對「單筆實際耗電量」的預測範圍。因此，要用實際測試值計算 95% 涵蓋率時，主要應檢查 PI。

第二，傳統 OLS 區間依賴模型與誤差假設。即使計算得到 95% PI，也不能保證時間相關、偏態及異質變異的真實資料一定有 95% 涵蓋率。這正是本階段要用實測結果驗證的核心問題。

Step 5：Evaluation 已完成

已延續 Step 4 的真實資料與鎖定模型，完成五大回歸假設檢驗、OLS 95% 信賴區間與預測區間、全測試集涵蓋率，以及連續 72 小時的預測圖。所有結果已整合進 **Markdown 研究筆記 v5**。

一、五大回歸假設檢驗結果

檢查項目（Test，VIF 除外）	方案 A：14 特徵	方案 B：28 特徵
Durbin–Watson	0.5831	2.0704
Residual ACF lag 1	+0.6876	−0.0359
BP LM 統計量	254.53	286.23
BP p-value	3.32×10^{-46}	1.31×10^{-44}
Skewness	3.157	3.211
Excess Kurtosis	14.122	21.691
Jarque–Bera p-value	極小	極小
Training Max VIF	382.45	405.34

最重要的發現是 DW 的改善。 加入 Lag 後，DW 從 0.5831 上升到 2.0704，表示殘差的一階正自相關大幅降低。

但其餘檢驗指出，兩個模型仍有異質變異、非常態殘差及嚴重共線性。DW 接近 2 並不代表所有延遲下的殘差都互相獨立。

實際模型殘差計算的 DW 與一階 ACF 比較圖。

二、95% 預測區間：整體達標，但高耗電時失準

Test 統計	方案 A	方案 B
Test RMSE	89.20 Wh	61.40 Wh

95% PI 實測涵蓋率	96.49%	95.47%
平均 PI 寬度	384.21 Wh	268.07 Wh
PI 下界為負數的比例	95.47%	87.20%
高耗電 >400 Wh 涵蓋率	0%	24.64%

方案 B：Test 前 432 筆（連續 72 小時）。實際值、OLS 預測值、95% 平均 CI 與單筆 PI。

這個實驗非常適合放入報告，因為它清楚顯示：

95% PI 的整體 Coverage 接近 95%，不代表每種耗電負荷下都具有 95% 可靠度。

低負荷資料占大多數，較寬的 PI 能涵蓋幾乎所有低耗電觀測；但高耗電尖峰經常超出上界。異質變異、殘差右偏與厚尾，使傳統 OLS 區間的名目涵蓋率不能直接視為可靠保證。計算使用 `statsmodels` 的 OLS 預測區間與標準回歸診斷方法。 GitHub +1

三、完成檔案

Step 5 完整實測成果 ZIP

包含完整 CSV、Step 4 鎖定模型、Step 5 Python、Markdown v5、統計 CSV、13 張新圖，以及先前階段所需圖表。

下載完整成果 ZIP ↗

Markdown 研究筆記 v5

下載 MD v5 ↗

Step 5 Python 完整程式

下載 Python ↗

也可分別取得 五大假設統計 CSV ↗、逐項 VIF ↗、PI 分負荷涵蓋率 ↗，以及 方案 A 72 小時預測圖 ↗。

研究進度：Step 1–5 已完成。 下一階段剩下實際使用 NotebookLM 進行文獻研究、比較主流或更優解法，然後整理 CRISP-DM 正式 PDF、GPT 對話匯出及最終學號 ZIP。

diagnostics_statistics.csv
試算表

vif_train_details.csv
試算表

coverage_by_load.csv
試算表

02_intervals_A_best14_72h_zoom.png
圖像

你說：

「太棒了！Step 1–5 已經全部完成，我也已經實際使用 Google NotebookLM 完成文獻與主流解法研究了。現在請幫我進行最後的 **Step 6：Deployment（模型部署與推論示範）與最終繳交檔案總整理**。

請幫我一次完成以下三項最終產出：

1. 完成 Step 6：Deployment（新樣本預測與模型解釋）

- 示範如何載入訓練好的最佳模型 Pipeline（含 `StandardScaler` 與選定的特徵子集），對測試集中的幾筆典型樣本（例如：日常低基載時段 vs. 照明與家電開啟的高耗電時段）進行預測，輸出點預測值與 95% 預測區間，並利用回歸係數（Coefficients）解釋各特徵對預測結果的貢獻。
- 說明此模型在真實智慧家庭能源管理系統（HEMS）中的部署情境與限制（例如：純環境模型可用於感測器異常偵測或基載估計；Auto Regression 模型則適合短期即時負載預警）。

2. 在報告中加入作業規定的『NotebookLM 摘要』、『主流或更優解法比較』與『GPT 輔助內容標示』

請在最終版 Markdown 報告中，明確新增以下兩個標示區塊（並將我們本研究 Step 4 & Step 5 的真實測試集數據填入比較表中）：

- **區塊一：`### 【NotebookLM 摘要】網路同主題解法與原始文獻研究`**

  請完整放入以下我實際透過 NotebookLM 研究原始論文（Candanedo et al., *Energy and Buildings*, 2017）與 Kaggle 主流解法所產出的真實摘要（共約 380 字）：

『本研究透過 Google NotebookLM 彙整 UCI 原始文獻（Candanedo et al., 2017）與 Kaggle 社群高分公開解法。

1. **問題背景與特徵特性**：本研究資料集涵蓋低能耗住宅 4.5 個月之室內溫濕度（ `T1 ~ T9` 、 `RH_1 ~ RH_9` ）、室外氣象與兩個無關隨機變數（ `rv1` , `rv2` ）。目標變數 `Appliances` 呈強烈右偏分布（待機基載約 40~60 Wh，尖峰高達 1,080 Wh）；且特徵存在嚴重多重共線性（如 `rv1` 與 `rv2` 完全共線、室內外溫濕度高度相關）。
2. **傳統線性回歸瓶頸**：單純利用環境溫濕度進行 OLS、Ridge 或 Lasso 多元線性回歸時，測試集解釋力（R^2）僅約 0.05~0.16。主因是家電開關屬非線性階躍變化，線性模型無法捕捉突發尖峰，且殘差具強烈正自相關與異質變異，嚴重違反了傳統回歸假設。
3. **特徵工程與選擇**：主流解法透過 RFE 或 Lasso 成功剔除無統計顯著性的隨機變數（ `rv1` , `rv2` ）。加入時間週期特徵（如距離午夜秒數 NSM、小時）能捕捉居民日常作息規律；導入自回歸**滯後項（Lag features）**則顯著利用相鄰時間的強慣性，使線性模型的 R^2 躍升至 0.55~0.60 以上。
4. **主流與更優解法比較**：相較於線性模型，非線性集成樹模型（如 Random Forest、GBM 與 XGBoost）能自動學習時間與溫濕度的非線性交互作用，測試集 R^2 提升至 0.57 以上（RMSE 降至約 66 Wh），大幅突破傳統回歸之預測瓶頸。』

    - 緊接著請在摘要下方附上**「本研究實測模型 vs. 原始論文與網路主流更優解法綜合比較表」**（欄位包含：模型名稱、特徵配置、RMSE、R^2、優缺點與統計假設特性，並將我們 Step 4 與 Step 5 跑出的真實數據與論文的 LM / SVM / GBM / RF 數據並列比較）。

- **區塊二： `### 【GPT 輔助內容】AI 協作歷程說明`**

  清楚條列本次作業中如何使用 GPT 輔助完成 CRISP-DM 六階段探討、五種特徵選擇演算法實作、五大回歸假設檢驗程式撰寫與結果驗證。

3. 產出最終繳交格式的檔案包

- **主程式 `5115056030_hw2.py`** ：請將 Step 1 ~ Step 6 的核心流程整合成單一、結構清晰、有完整註解且可直接執行的 `5115056030_hw2.py` 。
- **最終完整報告 Markdown（以及正式報告 PDF）**。
- 將上述所有最終檔案打包成專案 ZIP 供我下載。」

處理時間為 12m 36s

ChatGPT 說：

Step 6：Deployment 推論示範

已成功載入 Step 4 的模型，並建立包含 `StandardScaler` 、特徵選擇及回歸模型的可儲存 Pipeline。重新載入後，預測值與原模型一致。

以下是從保留的 Test 中挑選的實際觀測案例，並非人工假設數據。

實際耗電量	A：14 特徵預測	B：28 特徵預測
60 Wh	79.56 Wh	63.40 Wh
60 Wh	80.66 Wh	58.15 Wh
560 Wh	173.41 Wh	118.05 Wh
540 Wh	181.83 Wh	359.18 Wh
660 Wh	153.15 Wh	488.30 Wh

這些案例清楚說明：Lag 模型在部分高耗電時段能明顯改善預測，但當家電突然開啟、過去負荷尚未反映這個變化時，仍可能嚴重低估尖峰。例如實際 560 Wh 的時段，Lag 模型只估計 118.05 Wh。

本次也已對每個示範樣本計算 95% PI，並分解各個標準化特徵對預測值的線性貢獻。由於共線性偏高，這些貢獻適合解釋模型計算過程，不能當成特徵的因果影響。

Step 6 完成：最終作業檔案已產出

已完成模型部署、NotebookLM 摘要整合、文獻比較，以及 Step 1–6 的主程式與正式報告。

5115056030_hw2.zip

約 11 MB · 86 個檔案 · 已通過 ZIP 完整性檢查

下載作業成果 ZIP ↗

整合主程式

Step 1–6 單一 Python 程式，已實際重跑成功。

下載 5115056030_hw2.py ↗

正式報告 PDF

17 頁 A4，包含 CRISP-DM 六階段、模型結果、圖表、NotebookLM 與 GPT 標示。

下載正式 PDF ↗

完整 Markdown 報告與研究筆記

正式報告 MD ↗ · 累積研究筆記 v6 ↗

最終研究成果

模型	Test RMSE	Test R^2
A：14 特徵 LinearRegression	89.20 Wh	0.0366
環境 25 特徵基準	88.25 Wh	0.0570
B：環境 + 3 Lag	61.40 Wh	0.5435
原論文 LM	93.18 Wh	0.16
原論文 SVM	70.74 Wh	0.52
原論文 GBM	66.65 Wh	0.57
原論文 RF	68.48 Wh	0.54

文獻數字已核對 Candanedo et al. (2017) Table 5。**由於論文與本研究的資料切分、特徵不同，不能直接當作同條件競賽排名。** ORBi UMONS

Step 6 模型部署已驗證

兩套 Pipeline 均已儲存並重新載入，包含標準化與回歸推論流程。另已產出六筆實際測試樣本的點預測、95% PI 以及特徵係數貢獻分析。

例如，某筆低負荷樣本實際耗電 60 Wh，方案 B 預測為 63.40 Wh；但某筆突然升高至 560 Wh 的尖峰，方案 B 僅預測 118.05 Wh。這個落差已寫入正式報告，說明 Lag 模型仍無法可靠預測所有突發負荷。

繳交前還差一項

完整的 GPT 對話紀錄 PDF 尚未放入 ZIP。

我已完成報告中的「【GPT 輔助內容】」與「【NotebookLM 摘要】」區塊，並收錄你提供的 NotebookLM 研究文字。但課堂另外要求的**原始 ChatGPT 全程對話 PDF**，仍需要你從聊天介面使用瀏覽器列印或 pdfCrowd 匯出。

請將它命名為 `GPT_對話紀錄.pdf` ，加入 ZIP 內的 `5115056030_hw2` 資料夾，再重新壓縮上傳。

完成這項後，才算補齊原先要求的全部繳交項目。